

基于RGB与骨骼数据的人体行为识别综述

李全伟, 仇大伟, 刘 静⁺, 逯英航

山东中医药大学 医学信息工程学院, 济南 250355

⁺ 通信作者 E-mail: liuj_jn@163.com

摘 要: 人体行为识别是计算机视觉领域中的重要研究方向, 在人机交互、医疗康复、自动驾驶等领域具有广泛应用和重大意义。由于其方法的重要性和前沿性, 对该领域进行全面、系统地总结具有极其重要的意义。深入探讨了基于RGB和骨骼数据模态的人体行为识别方法; 按照特征学习方式的不同, 分为基于传统机器学习的手工特征提取方法和基于深度学习的深度特征提取方法。介绍了行为识别的基本流程, 并总结了公开数据集。详述了基于RGB和骨骼数据模态的识别方法。对于RGB数据, 分析了基于2D CNN、RNN和3D CNN的特征提取方法; 对于骨骼数据, 介绍了自上而下和自下而上的姿态评估算法, 重点分析了基于RNN、CNN、GCN、Transformer和混合神经网络的分类算法。最后, 展望了未来深度学习在人体行为识别中的五个研究方向。

关键词: 行为识别; 计算机视觉; RGB数据; 骨骼数据; 特征提取; 深度学习

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.2407-0456

Review of Human Behavior Recognition Based on RGB and Skeletal Data

LI Tongwei, QIU Dawei, LIU Jing⁺, LU Yinghang

School of Medical Information Engineering, Shandong University of Traditional Chinese Medicine, Jinan 250355, China

Abstract: Human behavior recognition is an important research direction in the field of computer vision, which is widely used and of great significance in the fields of human-computer interaction, medical rehabilitation, and automatic driving. Due to the importance and cutting-edge of its methodology, a comprehensive and systematic summary of the field is of utmost importance. In this paper, human behavior recognition methods based on RGB and skeletal data modalities are discussed in depth. According to the difference of feature learning method, human behavior recognition methods can be divided into manual feature extraction method based on traditional machine learning and deep feature extraction method based on deep learning. Firstly, the basic process of behavior recognition is introduced and the publicly available datasets are summarized. Then, the recognition methods based on RGB and skeletal data modalities are detailed. For RGB data, feature extraction methods based on 2D convolutional neural networks, recurrent neural networks, and 3D convolutional neural networks are analyzed. For skeletal data, top-down and bottom-up pose evaluation algorithms are presented, with a focus on analyzing classification algorithms based on convolutional neural networks, recurrent neural networks, graph convolutional neural networks, Transformer and hybrid neural networks. Finally, five future research directions for deep learning in human behavior recognition are envisioned.

Key words: behavior recognition; computer visualization; RGB data; skeletal data; feature extraction; deep learning

行为识别作为计算机视觉和人工智能领域的重要任务之一, 致力于识别和解释人类行为模式。其在人机交互^[1]、医疗康复^[2]、自动驾驶^[3]等领域中具有重要应用

价值。

近年来, 随着传感器技术的不断进步, 用于捕捉和表示人类动作的数据模式变得越来越多样化, 其中包括

基金项目: 国家自然科学基金面上项目(82174528); 山东省专业学位研究生教学案例库建设项目(SDYAL21054); 山东中医药大学青年科研创新团队项目(校科字[2024]1号); 山东中医药大学科学研究基金面上项目(KYZK2024M14)。

作者简介: 李全伟(2000—), 男, 硕士研究生, CCF会员, 研究方向为行为识别与深度学习; 仇大伟(1975—), 男, 硕士, 副教授, 研究方向为医学图像处理、机器学习; 刘静(1980—), 女, 硕士, 教授, CCF会员, 研究方向为医学图像处理与分析、机器学习、中医智能设备与研发; 逯英航(2000—), 男, 硕士研究生, 研究方向为表面肌电与深度学习。

收稿日期: 2024-07-26 **修回日期:** 2025-01-08 **文章编号:** 1002-8331(2025)08-0062-21

RGB、骨骼、深度、红外和点云等不同的数据模态。目前,基于RGB和骨骼数据模态的人体行为识别方法已成为最流行的研究方向。这两种模态的结合充分利用了RGB图像的丰富视觉信息与骨骼数据的结构化优势,使模型能够更全面地捕捉人体运动的细节。

RGB图像作为传统视频的主要数据来源,具备丰富的视觉信息,包括颜色、纹理和背景等,能够有效捕捉动作中的细节,这使得RGB数据在各种应用领域中具有广泛的应用潜力,能够提供直观的场景理解和细腻的行为识别。骨骼数据通过姿态估计技术获取人体关节的三维坐标,具备高度抽象性和良好的结构化特性,能够有效表示动作的核心要素。骨骼数据排除了背景干扰,简化了动作表示,处理成本低,且对外界干扰具有较强的鲁棒性,适用于高效处理和快速响应的场景。

相比RGB和骨骼数据,深度数据虽然能提供场景深度信息,但应用范围受限于专用硬件。红外数据虽不依赖光照,但分辨率较低,难以捕捉细节。点云数据虽然精确,但成本高、处理复杂,主要用于自动驾驶和3D建模等领域。因此,基于RGB和骨骼数据模态的人体行为识别方法成为当前研究的重点方向之一。

目前已有一些学者在人体行为识别方面进行了综述。Rahmani等人^[4]介绍了不同模态数据下的行为识别技术,但在基于骨骼数据的人体行为识别技术方面未提及流行的Transformer技术。Ren等人^[5]详细介绍了深度学习在骨骼数据方面的应用,但未涉及基于骨骼的传统手工特征的方法。黄倩、卢健等人^[6-7]对基于骨骼的行为识别技术进行了详细介绍,但却未提及基于RGB数据的人体行为识别技术。

在最新的研究中,人体行为识别技术在多个领域得到了广泛应用,特别是在智能监测和安全管理等场景中展现出重要价值^[8-10]。行为识别技术可以通过优化特征提取方法和模型设计,来有效应对复杂场景中的识别挑战,提升系统的精准度和稳定性。例如,Ni等人^[8]提出的算法在智慧城市的行为识别任务中实现了关键点检测的准确率超过80%,有效支持了智能监控和行为分析的需求。Xu等人^[9]的BiST-GCN-CBAM算法则针对监控视频中的背景干扰和多角度拍摄问题,在NTU-RGB+D 60和Kinetics-skeleton数据集上显著提升了行为识别的准确性,增强了监控系统的可靠性和实用性。此外,Zheng等人^[10]开发的轻量级卷积神经网络在跌倒检测中实现了95.79%的总体准确率和95.5%的帧识别准确率,显示出在老年人监护中的广泛应用前景。这些研究成果表明,人体行为识别技术已成为智能社会建设中的关键技术之一,在公共安全和健康管理等领域展现出巨大应用潜力。

现有研究综述中缺乏对基于RGB图像和骨骼数据模态的人体行为识别方法的全面系统概述。为了给人

体行为识别相关研究领域的未来工作提供参考,本文将相关文献和论文分为三个部分进行总结:(1)人体行为识别领域中RGB和骨骼数据模态的公开数据集介绍;(2)深入分析人体行为识别领域中基于RGB和骨骼数据模态的特征提取方法,按照特征学习方式的不同,进一步将这些方法分别分为基于传统机器学习的手工特征提取方法和基于深度学习的深度特征提取方法,并分析了优势和不足;(3)分析了目前研究中的挑战,并提出了对未来发展方向的展望。

1 数据集

随着人体行为识别技术的快速发展,研究人员已经构建了多种数据集来支持相关研究。按照数据集的类型进行分类,可以将其划分成不同的类别。其中,RGB数据集和骨骼数据集是两种关键的数据形式,分别捕捉了人体运动的彩色图像信息和三维骨架信息。这些数据集涵盖了广泛的动作类别和场景环境,为研究人员提供了丰富的实验材料。在本章中,将重点介绍几个具有代表性的RGB数据集和骨骼数据集。

1.1 RGB数据集

在RGB行为识别领域,不同的数据集为研究提供了多样化的实验基础。表1列出了常用的RGB数据集,其中涵盖了不同的视频数量和类别类型。通过这些数据集的对比分析,能够有效评估RGB视频在人类行为识别任务中的表现。

表1 RGB数据集
Table 1 RGB data sets

Data set	Year	Number of videos	Number of categories
HMDB51	2011	6 766	51
UCF50	2011	6 681	50
UCF101	2012	13 320	101
Kinectis-400	2016	306 245	400
Kinetics-600	2017	495 547	600
Kinetics-700	2018	650 317	700
Something-v1	2017	108 499	174

HMDB51数据集^[11]包含51个不同的人类行为类别,如“跳”“吻”和“笑”等,共由6 849个视频剪辑组成,每个行为类别都包含至少101个视频剪辑,视频片段的分辨率一般为320×240,且每个片段时长大约3 s。每个视频片段都经过人工标注,确保类别标签的准确性。标注工作由至少两个人工验证,以确保一致性。虽然HMDB51数据集在规模上相对较小,但它包含了丰富的人类行为类别和高质量的标注信息,这使得它成了一个非常有价值的数据集。

UCF101数据集^[12]由美国中佛罗里达大学计算机视觉研究中心发布。该数据集被广泛应用,收集自YouTube,是UCF50数据集^[13]的扩展,具有更大的多样

性和挑战性。UCF101数据集提供了来自101个动作类别的13 320个视频,总时长达到27 h。这些动作类别涵盖了广泛的领域,如“打篮球”“骑自行车”“划船”等,每个动作类别都有大约100至200个视频示例。

Kinectis数据集由DeepMind团队发布。Kinectis-400数据集^[14]是一个专注于视频行为识别的大规模、高质量数据集。这个数据集包含了400种不同的人类动作类别,每种类别都有至少400个视频剪辑。每个剪辑大约持续10 s,且都来自不同的YouTube视频。这些数据涵盖了人与物体的交互、人与人的交互等多种场景。Kinetics-600数据集^[15]在Kinetics-400的基础上进行扩展,包含了约500 000个视频片段,新增了200个动作类别,总数达到600个。Kinetics-700^[16]进一步扩展了数据集的规模,包含约650 000个视频片段,新增约100个动作类别,总数达到700个。

Something-Something-v1数据集^[17]包含108 499个视频,这些视频涵盖了174个不同的人类动作类别,每个视频都对应一个动作描述。数据集被划分为训练集(86 017个视频)、验证集(11 522个视频)和测试集(10 960个视频)。数据集中的视频帧已经被分割并保存为JPG图像,这使得数据预处理变得更加简单。

此外,EPICKITCHENS-55^[18]、ActivityNet^[19]等数据集也被广泛使用。

1.2 骨骼数据集

与RGB数据集相比,骨骼数据集由于其对光照和背景复杂度的鲁棒性,在人体行为识别中展现了巨大的潜力。表2列出了主要的骨骼数据集,包括各数据集的关键参数。分析这些骨骼数据集的结构和特点,有助于进一步理解骨骼数据在行为识别中的应用。在模态一栏中用RGB、IR、D和S分别代表RGB模态数据、红外模态数据、深度模态数据和骨骼模态数据。

CAD-60数据集^[20]包含了在厨房环境中进行的60个日常活动中的不同活动视频,每个活动都由RGB视频和深度视频组成。而CAD-120数据集^[21]作为CAD-60数据集的扩展,进一步丰富了活动类别和复杂度,包含了120个更为广泛和精细的室内活动视频。这两个数

据集不仅提供了RGB和深度视频数据,还附带了详细的标注信息,如人体和物体的边界框坐标、姿态估计以及活动标签等。

UTKinect-Action3D数据集^[22]是一个专门设计用于从深度序列中准确识别和分析人体动作的数据集。通过利用Kinect相机技术,该数据集不仅捕获了RGB图像和深度图像,还提供了3D骨骼数据。该数据集涵盖了10种日常生活中常见的动作行为,如走路、坐下、站起等。这些动作由10位不同的受试者重复执行,确保了数据的多样性和真实性。

NTU RGB+D数据集^[23]由新加坡南洋理工大学创建,包含60个动作类别和56 880个视频样本。每个样本都包含RGB视频、深度图序列、3D骨骼数据和红外视频。数据集通过3个Kinect v2相机同时捕获,以多角度捕捉动作细节。数据集的动作分为日常行为、互动行为和医疗行为3类,涵盖了广泛的场景,具有高度的多样性。NTU RGB+D 120数据集^[24]是该数据集的扩展,增加了60个额外的动作类别和57 600个视频样本,总共包含120个动作类别和114 480个样本。

MSR Action3D^[25]和MSR DailyActivity3D^[26]都是微软研究院发布的用于行为识别研究的三维动作数据集。MSR Action3D数据集涵盖了20种常见的动作类别,每个类别包含了来自多个演示者在不同视角下的动作演示和相应的三维骨骼信息。相比之下,MSR DailyActivity3D数据集专注于日常活动的识别,包含了16种日常活动类别,每个类别同样包括了多个演示者的动作演示和相应的三维骨骼信息。

Kinetics-Skeleton数据集^[27]是一个用于行为识别研究的三维骨骼数据集,由DeepMind发布。该数据集是Kinetics数据集的一个扩展,提供了与Kinetics视频数据对应的三维骨骼信息。Kinetics-Skeleton数据集包含了各种动作类别的视频片段,并为每个视频片段提供了相应的骨骼关键点坐标序列。这些骨骼关键点包括了人体的关键部位,如头部、肢体和关节等。

SYSU 3D数据集^[28]由中国中山大学发布,涵盖30个不同的动作类别,每个类别包括多个演示者在不同视

表2 骨骼数据集
Table 2 Skeletal data sets

Data set	Year	Number of videos	Number of categories	Number of subjects	Modality	Sensors	Number of joints
CAD-60	2011	60	12	4	RGB,S	Kinect v1	15
CAD-120	2013	120	20	4	RGB,S	Kinect v1	15
UTKinect-Action3D	2012	200	10	10	RGB+D+S	Kinect v1	20
NTU RGB+D	2016	56 880	60	40	RGB+IR+D+S	Kinect v2	25
NTU RGB+D 120	2019	114 480	120	106	RGB+IR+D+S	Kinect v2	25
MSR Action3D	2010	567	20	10	D+S	Kinect v1	20
MSRDailyActivity3D	2012	320	16	10	RGB+D+S	Kinect v1	—
Kinetics-Skeleton	2017	306 245	400	—	RGB	YouTube	18
SYSU 3D	2015	480	12	40	RGB+D+S	Kinect v1	21

角下的动作演示,并且每个动作序列都包括了从多个摄像头角度捕获的三维骨架数据。

此外, Northwestern-UCLA 数据集^[29]、UWA3D Multiview II数据集^[30]也被广泛应用。

2 基于RGB的人体行为识别方法

RGB数据较容易获取且成本较低,但容易受到图像质量、照明条件和背景噪声的影响,计算速度也较慢。传统的RGB行为识别方法依赖手工制作特征,而现代方法则通过深度学习来自动提取特征。下面将分别对基于RGB的手工特征方法和深度学习方法进行综述。

2.1 基于RGB视频的手工特征方法

手工特征提取的目的是获取视频中能够代表人体运动的时空变化行为特征。基于RGB的手工特征方法主要分为三类:基于时空体积的方法、基于时空兴趣点的方法和基于轨迹特征的方法。

2.1.1 基于时空体积的方法

基于时空体积的方法主要采用模板匹配技术,使用三维时空模板进行人体行为识别。早期,Bobick等人^[31]使用轮廓描述人体运动信息,提出了运动能量图(MEI)和运动历史图(MHI),分别表示动作的空间和时间特征,如图1所示。Davis等人^[32]进一步使用MEI和MHI图像来提取动作特征。首先,通过MEI表现动作的位置,接着利用MHI表现动作的时间信息,最后使用马氏距离来比较动作特征,从而实现特征匹配。




图1 视频帧与运动能量图和运动历史图对比

Fig.1 Comparison of video frames with motion energy map and motion history map

2.1.2 基于时空兴趣点的方法

基于时空兴趣点的方法通过检测视频序列中的关键时空兴趣点来描述和表示动作。如图2所示,这些兴趣点通常位于视频序列中显著的时空位置,对于描述动作信息至关重要。最经典的方法为3D-Harris时空特征点^[33],它扩展了传统的Harris检测算法,结合了视频序列

的时域和空域信息,识别兴趣点。然而,这种方法易受阴影和高光等光度现象的影响,Everts等人^[34]提出了color STIPs,使用颜色描述符,利用多通道色度不变量表示颜色信息。此外,Zhu等人^[35]提出将RGB视频中的兴趣点应用于对齐后的深度序列,来深入理解深度数据上的时空兴趣点特征。




图2 四个不同数据集的深度序列进行时空兴趣点检测的示意图

Fig.2 Schematic of spatio-temporal interest point detection with depth sequences from four different datasets

2.1.3 基于轨迹特征的方法

基于轨迹特征的方法是利用视频序列中目标的运动轨迹信息来进行行为识别的。其中,最为成功的方法是由Wang等人^[36]提出的密集轨迹法(DT)。这种方法借鉴了密集采样兴趣点的方法,通过采集密集点云并运用光流法跟踪特征点来获取密集轨迹,然后计算轨迹的位移信息进行识别,并提取运动轨迹的边界信息,以更精确地描述人体行为。Wang等人^[37]在DT的基础上进行了改进,提出了改进密集轨迹(IDT),改进了轨迹采样和特征描述,并引入了运动边界描述符,提高了人体行为表示和识别能力。Vig等人^[38]在DT的基础上使用显著性映射算法剪裁背景特征,使视频表示更紧凑,从而可以更好地表现人体行为。虽然基于轨迹特征的方法在行为识别和行为分析中有较高的识别准确率,但其仍然存在遮挡和背景干扰问题,并且需要精确的目标检测和跟踪。

基于RGB视频的手工特征提取方法具有直观性,然而,这些方法对光照变化、背景复杂度等环境因素敏感,容易受到噪声干扰。特征提取过程复杂且依赖经验,实时性较差,难以在实时应用中使用。

2.2 基于RGB视频的深度学习方法

随着深度学习技术的飞速发展,基于深度学习的人体行为识别方法取得了巨大进展,在识别精度和鲁棒性方面均优于传统的基于手工特征的方法。基于RGB的深度学习主要可以分为基于双流架构的方法、基于RNN的方法和基于3D CNN的方法。表3总结了这些方法的机制、优势、局限性和适用场景。

2.2.1 基于2D CNN的方法

Two-stream 2D CNN(双流2D卷积神经网络)框架通常包含两个2D CNN(二维卷积神经网络)分支,用于

表3 基于RGB视频的不同方法的特点比较
Table 3 Comparison of features of different methods based on RGB video

方法	机制	优势	局限性	代表性算法	特点
基于手工特征的方法	提取图像中的关键特征,如光流、SIFT、HOG等,通过传统机器学习算法分类	计算复杂度低,易于实现和解释	特征表达能力有限,对复杂动作和长时间序列的适应性差	MEI和MHI	通过MEI和MHI有效捕捉动作的空间与时间特征,适合简单动作提取,但对复杂动作适应性不足
				color STIPs	引入颜色描述符增强时空兴趣点检测鲁棒性,显著降低光照变化影响,但对颜色依赖较强
				密集轨迹法(DT)	结合密集采样与光流提取丰富运动信息,适用于复杂场景,但计算成本较高
2D CNN	分别处理RGB图像和光流图像,结合空间和时间信息进行识别	能有效捕捉空间和时间信息,提高动作识别的准确性	计算复杂度较高,对光流计算依赖大,对复杂动作识别效果有限	Two-stream CNN+SVM	通过空间网络处理RGB帧和时间网络处理光流,结合外观与运动特征进行视频识别,适合多场景,但光流计算要求高
				TSN	将视频分为三个片段,通过双流网络处理并平均池化生成预测结果,稳定性高,但需大量训练数据
RNN	使用RNN或LSTM处理视频数据的时间序列信息	对时间序列数据建模能力强,适合长时间序列的动作识别	计算复杂度高,训练时间长,长时间序列处理可能存在信息丢失问题	LRCN	结合2D CNN与LSTM,利用帧级RGB特征生成动作标签,适合人体行为识别,但训练时间较长
				DB-LSTM	通过双向LSTM和密集跳跃连接增强时间模式建模能力,计算开销大
3D CNN	使用3D卷积核同时提取空间和时间特征	能同时捕捉时空特征,识别准确性高,适合复杂动作识别	计算复杂度极高,对硬件要求高,训练数据需求大	ACTION-Net	利用多径激励机制精细化建模空间-时间、信道和运动模式,适合高精度分析,但实施成本高
				CIDC(I3D-NL)	设计通道独立定向卷积嵌入I3D模型,有效捕捉长时间动态,时序感知效果佳,但结构复杂,难以训练

从RGB视频中提取不同的输入特征进行识别,最终结果通过融合策略获得。最经典的双流CNN模型是由Simonyan等人^[39]提出,由空间网络和时间网络组成。视频中的每个独立的RGB帧和基于多帧的光流分别被输入到空间流和时间流,以学习视频的外观特征和运动特征。最后,通过融合这两个流的分类得分生成最终的结果。

在Simonyan等人^[39]的基础上,后续研究者通过优化计算效率和改进特征提取方式对双流框架进行了扩展。Karpathy等人^[40]通过将低分辨率RGB帧和高分辨率中心裁剪图像输入两个独立的流,以加快计算速度并解决计算精确光流的高计算成本。Zong等人^[41]则进一步扩展双流结构,将双流CNN扩展为三流CNN,提出了一种名为多流倍增器R残差网络(MSM-ResNets)的行为识别模型,包括外观流、运动流和运动显著性流,分别捕获不同的信息,并通过乘性连接在流之间建立时空交互。

除了改进双流框架的输入形式外,另一部分研究则集中在提高模型对长期信息的捕捉和利用上。Bilen等人^[42]提出了一种基于RGB序列和光流序列构建动态图像的方法,通过秩集合将长期的全局外观和运动信息整合进模型中,从而使其能够处理更长时间尺度的行为识

别任务。此外,Wang等人^[43]也在双流网络的基础上进一步扩展,针对视频中的长期信息进行处理。他们将每个视频分割为三个片段,并利用双流网络处理每个片段,最后通过平均池化方法将三个片段的分类得分融合,生成视频级别的预测。

2.2.2 基于RNN的方法

RNN广泛用于时间序列数据分析,但传统RNN存在梯度消失问题,因此现在大多数方法倾向于采用门控RNN结构,如LSTM(长短期记忆网络)。基于RNN的方法通常先使用二维CNN提取特征,再使用LSTM进行人体行为识别。在此基础上,有许多学者进行了改进。

例如,Donahue等人^[44]引入了长期递归卷积网络(LRCN),该网络结合了二维CNN和LSTM,用于从帧级RGB特征生成单个动作标签。He等人^[45]提出了一种密集连接的DB-LSTM(双向LSTM网络),用于模拟视觉和时间上的正向和反向关联,同时结合密集的跳跃连接,增强了时间模式建模的能力。

为了进一步提升基于LSTM框架的识别性能,一些研究者引入了注意力机制。Sharma等人^[46]提出了带有空间注意力的多层LSTM模型,通过加权突显重要空间特征,有效提升了模型的表现。而Meng等人^[47]引入时间注意力机制,则利用LSTM来学习时间注意力,以加

权所有帧的特征。Li等人^[48]则引入空间和时间注意力机制,提出了视频LSTM,将卷积和基于运动的注意力融合到软注意力LSTM中,以更全面地捕捉空间和运动信息。Liu等人^[49]提出了一种基于时空显著性的多流残差网络(multi-stream ResNet),结合了空间流(RGB帧输入)、时间流(光流帧输入)和时空显著性流(时空显著性图输入),以减少背景干扰并提供有用的时空物体前景信息用于人类行为识别。

除了对LSTM的改进,一些研究者尝试结合RNN与其他方法。例如,Wu等人^[50]在他们的研究中,使用双流2D CNN模型来分别提取空间特征和短期运动特征。这两个特征流随后被独立地输入到两个LSTM中,从而构建了一个能够捕捉人体行为识别长期时间信息的模型。

尽管大多数基于RNN的方法依赖帧级CNN特征,但也有研究将二维CNN扩展到三维结构,以同时捕捉视频中对HAR至关重要的时空背景信息。

2.2.3 基于3D CNN的方法

与RNN不同,3D CNN(3D卷积神经网络)通过同时在空间和时间维度上进行卷积操作,能够直接提取视频中的时空特征。Ji等人^[51]最早提出3D CNN(3D卷积神经网络),通过使用人体检测器方法分割视频中的人体,然后将分割后的视频输入一个新颖的3D CNN模型,以提取视频中的时空特征。Zolfaghari等人^[52]提出了ECO架构,该架构能同时考虑视频的长时信息和局部信息,实现快速的视频处理和在线视频识别。该方法使用2D卷积网络处理单个帧的外观特征,使用3D卷积网络处理帧之间的时间关系,从而捕捉视频的整体特征。

然而,许多3D CNN模型对长时间视频中的时空依赖性处理不足。为了克服这一不足,Varol等人^[53]提出了长期时空卷积(LTC)框架,该框架通过牺牲一定的空间分辨率,显著扩大了三维卷积层的时空覆盖范围,从而更有效地模拟视频中的长期时空结构。与此同时,Li等人^[54]设计了一种通道独立定向卷积(CIDC),该卷积可以灵活地嵌入到I3D(inflated 3D ConvNet)模型^[55]中,以更有效地捕捉完整输入视频中的长时间动态。

针对数据模型需要大量训练数据的问题。Qiu等人^[56]通过将三维卷积分解为空间域的二维卷积与时域的一维卷积,大幅降低了计算成本,同时依然有效地模拟了三维卷积的效用。Lin等人^[57]则引入了一种新颖的时移模块(TSM),该模块通过沿时间维度移动部分通道的方式,巧妙地促进了相邻帧特征之间的时间交互,显著提升了模型处理视频数据的能力。Wang等人^[58]开发了ACTION模块,该模块利用多径激励机制,对空间-时间、信道和运动模式进行了精细化建模,为视频分析领域带来了全新的视角和方法。

尽管3D CNN在时空特征提取中表现出色,但其因

参数众多易出现过拟合现象。针对过拟合问题,Kim等人^[59]提出随机均值缩放(RMS)作为正则化方法。Li等人^[60]针对三维卷积在视频分类中计算成本高、效率低以及特征交互不足的问题,提出了一种新颖的通道张量化网络(CT-Net)。该网络将输入特征的通道维度分解为多个子维度的乘法,从而降低了计算成本,并提高了特征之间的交互能力。

此外,研究者们还探讨了3D CNN与其他网络结构的结合,以提升动作识别的准确性。钱惠敏等人^[61]提出了一种结合3D CNN与双流网络的新方法,即基于通道剪枝的TPNLST-ResCNN(双流-非局部时空残差卷积神经网络)。该方法采用双流架构,分别在时间和空间两个子网络中引入ST-ResCNN(时空残差卷积神经网络),并通过均值融合策略整合两者的识别结果,提升了动作识别的准确性。

双流2D CNN在单帧和短时序任务中具备高效的特征提取能力,特别适用于智能视频监控中的行为检测。然而,由于其依赖于独立处理帧的方式,导致在识别连续动作和捕捉长时间序列信息方面有所不足。相比之下,RNN通过其时间序列建模能力,尤其是在结合LSTM后,能够有效捕捉视频中的长时间依赖性,在复杂动作识别中展现出出色的表现,但其高计算开销限制了实时应用的普及。3D CNN则通过同时在空间和时间维度上进行卷积操作,能够全面捕捉视频中的时空特征,在处理多动作交互和长时视频分析任务时具有明显优势。然而,3D CNN庞大的模型参数和高计算成本也带来了易过拟合的问题,尤其在训练数据不足时,这成为其应用的主要瓶颈。因此,这三种方法在不同任务中的表现差异明显,双流2D CNN适合短时高效任务,RNN适用于复杂时间序列分析,而3D CNN则在全面时空特征提取中表现卓越,但需谨慎应对其高计算成本和过拟合风险。

基于RGB视频的深度学习方法能够自动学习特征,具备处理复杂背景和光照变化的鲁棒性,但需要大量标注数据和高计算资源,且易受背景噪声、光照变化和摄像头角度影响,存在过拟合风险。相比之下,骨骼数据因其对光照和遮挡的鲁棒性,随着传感器和姿态估计技术的发展,逐渐成为人类行为识别的研究热点。

3 基于人体骨骼的人体行为识别方法

骨骼数据比其他模态数据,如RGB图像、深度图等包含更丰富的信息。它既包含关节之间的空间信息,又包含关节之间的时间信息,而且在考虑关节和骨骼时,空间域和时间域之间的共生关系提供了一个整体的视角。骨架数据本质上可以看作是拓扑图,属于非欧氏空间数据,这一模态与人体动作更加密切,因此许多研究人员使用骨架数据进行人体行为识别任务。基于人

体骨骼的行为识别方法主要分为基于姿态评估的方法、基于手工特征的方法和基于深度学习的方法。

3.1 基于姿态评估的方法

人体姿态估计法用于准确地提取骨架数据,是行为识别的基础内容之一。该方法从图像中识别出人体并提取人体关节点的坐标,一般检测头部、颈部、双臂以及双腿等人体重要关节点。能否精确地提取出关节点的坐标信息是影响行为识别准确度的重要因素。目前,人体姿态估计算法主要分为自上而下和自下而上的两类方法。

自上而下的方法先将图像中所有人体的骨架姿态分割出来,然后基于每一个独立的个体提取出人体关节点。具有代表性的算法如 AlphaPose 算法^[62],其对于遮挡部分不会任意提取,只能显示可见的部分,准确度较高。然而,随着图片上的人数增加,计算量增大,速度变慢,结果严重依赖第一步行人检测器的结果。Lyu 等人^[63]提出了一种基于 AlphaPose 与样本熵融合的步态分析方法,专门用于评估关节置换术后患者的恢复情况。该方法通过 AlphaPose 提取患者和健康人的足跟关键点轨迹,将其转化为特征向量,并结合样本熵进行分析。Yang 等人^[64]提出了一种跌倒检测算法,依托 AlphaPose 精准提取红外视频中的骨骼序列,并结合 ST-GCN(图卷积神经网络)模型进行分析,实现了跌倒行为的高效识别。改进后的模型在专有数据集上达到了 96% 的准确率,适用于近红外和热红外视频。

自下而上的方法则是先将图像中所有出现的人体关节点都提取出来,再把每个人的关节点进行聚类,连成人体骨架,进而提取图像中所有人体的骨架姿态。最具代表性的算法如 OpenPose^[65],与先进行人体定位后进行关节点检测的自上而下方法相比,其人体检测所需时间不会因为图像中人数增多而增加,适合于对检测速度要求较高的任务。Liu 等人^[66]提出了一种改进的 OpenPose 算法,充分利用其关键点定位能力,并通过角度测量增强检测效果。该方法优化了 OpenPose 算法中关键点的连接方式,进一步通过极限角度测量提升了姿态检测和行为识别的精确度。Chen 等人^[67]同样在 OpenPose 的基础上,结合 AdaBoost 算法与 SoftNet 模型,运用深度学习对视频进行分析,实现了动作分类、姿态估计和视频处理的有效集成。

尽管自上而下和自下而上的姿态估计算法各具优势,但它们面临着共同的挑战,如高计算成本和对大量标注数据的依赖。姿态估计模型的泛化能力通常受限于训练数据的多样性,在特定类型数据上训练的模型可能难以有效识别新领域或不常见的动作。基于少量关键点信息的细粒度动作识别方法虽然计算量小且对背景干扰不敏感,但忽略了人物外观和细节,识别效果因此受到限制。此外,这类方法高度依赖姿态估计算法的准确性,关键点检测的误差会直接影响最终结果。

Jhuang 等人^[68]基于 J-HMDB 数据集的实验表明,高水平的姿态特征,特别是时间序列中的姿态特征,对行为识别至关重要。不同算法在不同应用场景中表现出差异,AlphaPose 在高精度要求的场景中表现更优,而 OpenPose 则更适合需要实时处理复杂场景的任务。

3.2 基于骨骼的手工特征方法

在基于骨骼数据的人类行为识别研究中,研究者们提出了多种创新方法以提高识别的准确性和鲁棒性。其中,Hussein 等人^[69]提出了一项创新的识别方法,通过分析从深度数据中提取的三维骨架序列来识别人类动作。该方法引入了一种名为 Cov3DJ 的新型描述符,通过构建骨骼关节位置随时间变化的协方差矩阵来实现,如图 3 所示。Cov3DJ 描述符有效地捕捉了动作序列中的时间依赖性,并且由于其具有恒定的长度,因此不受序列长度变化的影响,从而提高了行为识别的稳定性和准确性。




图3 三维关节描述符的协方差构建示意图

Fig.3 Schematic of covariance construction for three-dimensional joint descriptors

为了提升智能家居监控机器人在跌倒检测方面的性能,Zhou 等人^[70]提出了一种创新的检测方法。该方法提取了一系列基于轮廓的特征,包括人体轮廓最小边界框的宽高比、椭圆的偏心率、归一化的中心矩以及 Hu 不变矩。在建模过程中,采用融合高斯混合模型的隐马尔可夫模型来区分跌倒行为与其他常见人体运动模式,如行走、弯腰、跑步和蹲坐。

为了更好地处理复杂的三维人体运动重建问题,You 等人^[71]开发了一种创新的姿势与网格协同演化网络,该网络通过利用三维姿势作为中间表征,将视频驱动的三维人体运动重建问题分解为姿势估计和网格顶点回归两个子任务。该网络设计了双流编码器结构和协同进化解码器,并借助图像引导的自适应层归一化技术,有效地实现了姿势与网格的精确重建。

Chaudhry 等人^[72]提出了一种新的生物启发式动态 3D 区分骨骼特征,用于人类行为识别,并取得了优异的性能。该方法借鉴了神经科学中灵长类动物下颞叶皮

层对3D形状的神经编码,使用线性动态系统建模动态中轴结构,并提出了新的区分度量指标。

在基于深度相机的研究中,Wang等人^[26]提出了一种新颖的行为识别方法。该方法使用局部占用模式特征描述关节的局部“深度外观”,并引入动作元的概念,通过挖掘每个动作中的关键关节组合来表示动作。同时,采用傅里叶时间金字塔特征描述动作的时间动态。

基于骨骼的手工特征方法具有较高的鲁棒性,不受光照和背景因素影响,计算成本低,适用于实时应用。然而,手工特征方法需要精心设计特征,特征提取过程

复杂。此外,仅依赖骨骼数据,忽略了图像中的细节和外观信息,可能导致信息丢失。

3.3 基于骨骼的深度学习方法

由于深度学习具有强大的特征学习能力,已被广泛应用于基于骨骼的HAR,并成为该领域的主流研究。根据所使用的主干网络的不同,基于深度的方法可以进一步分为基于RNN的方法、基于CNN的方法、基于GCN(图卷积神经网络)的方法、基于Transformer的方法和基于混合网络的方法。表4总结了这些方法的机制、优势、局限性和适用场景。

表4 基于人体骨骼的不同方法的特点比较
Table 4 Comparison of features of different methods based on human skeleton

方法	机制	优势	局限性	代表性算法	特点
基于姿态评估的方法	利用人体姿态估计算法提取人体关键点,通过分析关键点的时空变化进行动作识别	简单直观,计算复杂度低	受关键点检测精度影响大,对复杂动作识别效果不佳	AlphaPose	通过精准提取可见部分的骨架关节点进行姿态估计,适用于高精度要求的场景,但对行人检测结果依赖较大
				OpenPose	从图像中提取所有关节点,再聚类生成骨架,检测速度不会因人数增加而降低,适合实时处理复杂场景。但计算开销较大
基于骨骼的手工特征的方法	提取骨骼点的几何特征(如角度、距离),通过机器学习模型进行分类	不依赖深度学习模型,计算量相对较小,易于实现	特征表达能力有限,对复杂动作和长时间序列的适应性差	Cov3DJ	构建骨骼关节位置的协方差矩阵,捕捉时间依赖性,提高识别稳定性,但对噪声敏感
				Local Occupancy Pattern Features	使用局部“深度外观”特征和傅里叶时间金字塔特征描述时间动态,能够全面表示动作。但计算复杂度高,导致实时性较差
基于RNN的方法	结合RNN和LSTM处理骨骼数据的时序信息	提供了对时间序列的强大建模能力,适合长时间序列的动作识别	计算复杂度较高,长时间序列处理时可能存在信息丢失问题	HBRNN	通过分层处理骨架的五个区域并融合特征,提升人体行为识别的效果。但模型复杂度较高,会导致训练的时间成本增加
				IndRNN	通过调整学习率解决不同采样率下的行为识别问题,适应性强。但训练过程复杂
				GCA-LSTM	适应关注骨架序列中的关键关节,提升动作特征提取能力,但也可能忽略一些非节点信息,从而影响识别效果
基于CNN的方法	使用CNN提取骨骼数据的空间特征	能有效提取空间特征,提高识别的准确性	对时间序列信息建模能力有限,对动态复杂动作处理不佳	SkeletonNet	通过计算骨骼关节的幅度和方向值,编码时间动态。但对关节定位的准确度要求高
				SkeleMotion	同样通过计算骨骼关节的幅度和方向值,编码时间动态。但对关节定位的准确度要求高,与SkeletonNet类似
				JTM	通过三视图纹理图像表示关节轨迹的时空信息。但对图像数据要求较高
基于GCN的方法	通过GCN建模骨骼点之间的关系	能有效捕捉骨骼点的空间关系,提高识别的准确性	计算复杂度较高,训练时间长,适用于大规模数据集的处理有挑战	ST-GCN	以关节为顶点,时间序列为边,构建时空图进行骨骼行为识别。时空建模效果很好。但图构建过程复杂,计算和内存需求高
				Shift-GCN	采用轻量级图卷积操作,提升计算效率,适用于骨骼行为识别。但可能牺牲部分识别精度,特别是在复杂场景中
				EfficientGCN	通过早期融合关节位置、运动速度和骨骼特征,减少冗余参数,提升模型效率。但特征融合可能不够全面,影响识别效果
				MST-GCN	通过多尺度图卷积增强对动作识别的感知范围,适用于多种动作场景。但对计算需求较高,尤其在大规模数据集上
基于Transformer的方法	使用自注意力机制捕捉骨骼数据的全局信息	在处理长时序和复杂数据时表现突出,识别精度高	计算资源需求高,训练时间长,可能限制实际应用中的广泛部署	3Mformer	结合高阶变换器和多模态聚合策略,增强骨骼动作识别能力。但模型结构复杂
				STTFormer	利用时空元组自注意模块捕捉帧间关节的相关性,提升识别效率。但训练时间长,对计算资源要求高
				ST-TR	通过时空自注意力模块捕捉帧内和帧间的依赖关系,提升动作识别效果
基于混合神经网络的方法	结合多种特征和模型,如CNN、RNN、GCN等,进行综合识别	结合多种优势,识别精度高	融合不同模型和特征的复杂性高,计算资源需求大	STB-Former	结合GCN和Transformer,自注意力机制提升时间连续骨骼信息的建模能力
				HybridNet	结合GCN和CNN,捕捉时空补丁中的点间依赖关系,增强时空建模能力。但训练和调整相对复杂,可能需要更多的超参数调优

3.3.1 基于RNN的方法

基于RNN的行为识别方法通常将骨架帧转换为关节的向量序列,并通过RNN网络捕捉骨架帧序列中的时间动态特征。在这些方法中,LSTM、门控循环单元(GRU)、神经图灵机(NTM)是RNN的几种常见变体,其中LSTM应用最为广泛。

Du等人^[73]提出了一种端到端的HBRNN(分层循环神经网络),如图4所示。该模型通过将人体骨架按物理结构分为五部分并分别进行处理,随后将提取的特征分层融合,并通过单层感知器得出最终决策。Li等人^[74]引入了RNN树(RNN-t)模型,这是一种采用多个RNN构建的树形结构学习框架,有效地应对了单个网络在处理细粒度行为分类时遇到的挑战。

由于RNN空间建模能力上的不足,部分学者开始着力于解决此问题。Wang等人^[75]提出了一种双流RNN框架(dual-stream RNN),旨在并行处理时间序列动态和空间结构信息,如图5所示。该架构采用了LSTM单元处理骨骼序列,进一步分为堆叠和分层两种设计。在堆叠设计中,所有关节坐标直接输入LSTM单元,按帧顺序处理;在分层设计中,将人体划分为手臂、腿和躯干等五个区域,每个区域通过独立的RNN进行建模。Liu等人^[76]开发了一个时空LSTM模型用于三维人体行为

的识别,这个模型扩充了RNN到时空领域,以挖掘与行为直接相关的潜在信息。

与此同时,其他研究者在增强RNN对时空动态信息的捕捉方面也取得了重要进展。Veeriah等人^[77]提出了差分RNN(dRNN),该模型通过计算帧与帧之间显著运动导致的信息增益变化,来学习关键的时空信息。Lee等人^[78]设计了一个包含短期、中期和长期TS-LSTM网络的TS-LSTM(复合时空滑动LSTM)框架,以全面分析不同时间尺度上的运动变化。Li等人^[79]为了提升时空建模的复杂度,将注意力RNN和CNN模型结合,通过时间注意力模块在骨架序列中重新校准时间注意力,并使用时空卷积模块将校准后的序列视为图像处理。

此外,针对并非所有关节都能为动作分析提供有效信息的问题,Liu等人^[80]提出了一种基于全局上下文感知注意力的LSTM网络,能够自适应地关注骨架序列中的关键关节,以提升模型对动作特征的提取能力。针对RNN模型在不同采样率行为识别任务中的局限性,Gao等人^[81]提出了一种可变速率独立递归神经网络(VR-IndRNN),通过学习率调整方法,有效解决了可变时间步长下梯度反向传播带来的问题,显著提高了基于骨架的行为识别准确率。

针对传统双流卷积模型在人体识别中时空特征挖




图4 HBRNN示意简图

Fig.4 Schematic diagram of hierarchical recurrent neural network




图5 双流RNN架构示意图

Fig.5 Schematic diagram of dual-stream RNN architecture

掘不充分的问题,高治军等人^[82]提出了一种改进的双流卷积模型,该模型融合了CNN和LSTM网络的优势,并采用改进的可滑动长短时记忆网络、数据增强技术、Dropout正则化技术和Adam优化器,能够有效提取人体骨架的时空特征。

基于RNN的方法擅长处理序列数据,能够捕捉骨骼动作序列中的时间依赖关系。然而,RNN在处理长序列时容易出现梯度消失或梯度爆炸的问题,导致模型训练困难和性能下降。虽然LSTM和GRU等变种在一定程度上缓解了这些问题,但在处理长时间序列时仍然存在局限性,且训练速度较慢,难以有效利用骨骼数据的全局特征。

3.3.2 基于CNN的方法

基于CNN的行为识别方法通常是将骨骼序列转换为伪图像,将骨架数据表示为没有视觉语义信息的伪图像,并提取伪图像的特征,从而将行为识别任务处理为图片分类任务。然而,如何有效地结合空间和时间信息仍是一个具有挑战性的问题。

Li等人^[83]提出了一种新框架-CNN+Motion+Trans,用于动作分类和检测。该框架直接将原始骨架坐标和骨架运动输入CNN进行标签预测,并设计了一个骨架变换器模块来自动重新排列和选择重要的骨架关节。

Caetano等人^[84]提出了一种名为SkeleMotion的表示法,如图6所示。传统的骨架图像表示方法基于骨骼关节的空间结构,而SkeleMotion则通过计算骨骼关节的幅度和方向值来编码时间动态。

此外,为进一步提升时空特征的提取能力,Ke等人^[85]提出了一种基于深度学习的骨骼3D行为识别框架-SkeletonNet。该框架通过提取骨骼序列的时空信息,利用深度学习网络进行特征学习,从而实现了鲁棒且高效的行为识别。Li等人^[86]提出了一种基于卷积共现特征学习的端到端框架,用于骨骼行为识别。该框架通过分层聚合帧内和帧间信息,有效地学习到鲁棒的骨骼特征表示。

为了解决骨骼行为识别中关键关节的选择问题,Banerjee等人^[87]提出了一种基于骨架关键关节的模糊融

合CNN行为识别方法,该方法融合了四个互补特征表示,并利用Choquet积分进行模糊融合,以提高识别精度。

针对关节轨迹信息的处理,Wang等人^[88]提出了一种基于联合轨迹图(JTM)和CNN的实时人体行为识别方法,通过颜色编码将关节轨迹的时空信息从主、侧、俯三视图表示为三个纹理图像进行行为识别。然而,这种方法略显复杂,在映射过程中也失去了一些重要信息。为了解决这一问题,Li等人^[89]采用了一种平移尺度不变的图像映射策略。该方法首先根据人体物理结构将每帧图像中的人体骨骼关节分为五大部分,然后将这些部分映射为二维形式。这种方法使骨骼图像同时包含时间信息和空间信息。尽管这种方法在性能上有所提高,但由于没有将骨架的关节作为单独的点进行考虑,仍未能完全贴合现实情况。为了进一步解决这个问题,Li等人^[90]从几何代数的角度出发,提出了形状运动表示法。

梁成武等人^[91]设计了一种结合时空领域先验知识与CNN结构改进的骨架行为识别方法。该方法首先引入时空聚焦模块,通过领域知识引导模型关注关键特征。其次,利用长时空跨度领域的知识提出多尺度卷积融合模块,通过分组残差连接,扩展了卷积的时间感受野,使得模型在不增加大量参数的情况下,能够更好地捕捉长时空特征。

基于CNN的方法通过端到端、多尺度学习和参数共享等特点实现高效的特征学习,能够同时处理骨骼数据的空间和时间信息。然而,CNN在捕捉长时间依赖关系和骨骼序列的拓扑信息时存在局限性。CNN模型的内部结构复杂,决策过程难以解释,且在处理动态变化的骨骼数据时表现相对较弱。

3.3.3 基于GCN的方法

尽管RNN和CNN在处理图像、文本等欧式空间数据方面具有优势,但由于其输入只能是向量或伪图像,导致其难以处理骨骼等非欧式空间的数据。基于图结构的强大表现力和CNN的不断发展,GCN应运而生。

Yan等人^[27]首次提出了一种基于骨架行为识别的ST-GCN(时空图卷积网络)。该模型以人体关节作为时空图的顶点,以人体的物理关节连接及时间序列作为




图6 SkeleMotion构建方法示意图

Fig.6 Schematic diagram of SkeleMotion construction method

边,构建一个时空图。然后使用标准的 Softmax 分类器将通过 ST-GCN 获得的高阶特征图分类到相应的类别中。赵登阁等人^[92]针对现有时间卷积层的结构局限性,提出了一种 SMT-GCN(多尺度时空图卷积网络),通过引入多种不同尺度的卷积核和结构,使得网络能够更加全面地提取不同时间尺度的动作特征,从而提高了识别的效果。

随着对关节关系建模需求的提升,Li 等人^[93]提出了一种新颖的框架,称为 AS-GCN(动作结构图卷积网络),它能够有效识别人类动作,并通过拓扑图捕捉关节相关性。为了克服以往研究中忽略的隐式联合相关问题,AS-GCN 进一步将动作链接和结构链接融合至一个广义的骨架图中,该框架提供了更全面、更深入的行为识别和姿态预测理解。Shi 等人^[94]提出了双流自适应 GCN(2s-AGCN),通过反向传播算法统一或单独学习图的拓扑结构,无须手动设置。后续,Shi 等人^[95]又提出了一种用于基于骨架的行为识别的 MS-AAGCN(多流注意力增强自适应图卷积神经网络)。该方法在传统 GCN 基础上进行了改进,采用数据驱动的方式学习图结构,并引入空间、时间、通道注意力模块以增强模型对重要关节、帧和特征的关注度。该模型将人体骨骼的二阶信息与一阶信息相结合,并采用双流 GCN 架构同时利用关节和骨骼信息。

为了解决 GCN 在处理大规模图数据时计算复杂度高的问题,Cheng 等人^[96]提出了 Shift-GCN,采用移位图操作和轻量级点向卷积,替代了传统的重型图卷积。在这一研究思路下,Song 等人^[97]设计了 EfficientGCN 多流 GCN 模型,在早期阶段就融合了关节位置、运动速度和骨骼特征等输入分支,利用可分离卷积层和复合缩放策略大幅减少了冗余参数,提升了模型容量。Jiang 等人^[98]提出了一种名为 LMA-GCN 的轻量级改进图卷积网络,克服了深层 GCN 模型计算成本高的问题,通过结合多尺度自适应图卷积和轻量级时间卷积,显著降低模型复杂度和计算开销,同时保持识别性能。

在骨架行为识别的研究中,传统的 GCN 在处理关节与骨骼的关系时常存在不足。王琪等人^[99]提出了一种融合内在拓扑与多尺度时间特征的骨架动作识别方法。该方法通过增强对骨架动作中潜在关系的建模,克服了传统时间卷积的局限,显著提升了识别性能。与此同时,现有的骨架行为识别方法往往过于复杂,容易忽略其他特征和时间信息的有效利用。为此,Wang 等人^[100]提出了一种轻量级时态特征交叉抽取图卷积网络(TFC-GCN)。该网络引入关节相对位移特征、时间特征交叉提取块和缝合时空注意力块,以高效提取特征并获得更好的分类结果。

此外,GCN 虽然已成为骨架行为识别的关键特征提取方法,但在处理野外行为识别任务时仍存在局限

性。针对这一问题,Yang 等人^[101]提出了一种 MKE-GCN(多模态知识嵌入图卷积网络),通过自适应多模态聚合(AMA)模块和多模态知识蒸馏(MKD)策略,有效解决了多模态特征建模和“野外”处理能力不足的问题。Kang 等人^[102]针对高计算成本和大模型尺寸限制了实际应用的问题,提出了两种联合映射模块,旨在降低关节表示数量,减轻总体计算成本和模型尺寸。

针对骨骼行为识别中现有方法在多尺度关系建模和跨时空信息传播方面存在的局限性,Liu 等人^[103]提出了一种名为 MS-G3D 的算法,使用时空图来捕获人体动态,并通过多尺度图卷积和统一的时空图卷积算子 G3D,实现了有效的远程建模和跨时空信息传播。Chen 等人^[104]提出了一种新的通道拓扑细化图卷积网络(CTR-GCN),用于骨架行为识别。该方法通过动态学习不同的拓扑,有效地聚合不同通道中的关节特征,显著降低了建模通道拓扑的难度,并放松了图卷积的严格约束,使其具有更强的表示能力。Chen 等人^[105]提出了 MS-GC(多尺度空间图卷积)和 MT-GC(多尺度时间图卷积)模块,用于增强 GCN 在骨骼行为识别中的感知范围。通过这些模块的组合,设计了 MST-GCN(多尺度时空图卷积网络),实现了有效的动作表示学习和行为识别。

基于 GCN 的方法能够利用骨骼数据的拓扑结构,捕捉不同关节之间的关系,提供更为自然的时空特征表示。尽管如此,GCN 在处理大规模图数据时计算复杂度高,对动态变化的骨骼数据处理能力有限。此外,GCN 模型的设计和训练需要对图结构有深刻理解,增加了模型实现的复杂性。

3.3.4 基于 Transformer 的方法

Transformer 是由 Vaswani 等人^[106]提出的一种自然语言处理(NLP)核心神经网络模型,旨在取代传统的递归网络。该模型解决了两个主要问题:一是有效处理 LSTM 和 RNN 通常难以处理的超长序列;二是克服了经典 RNN 架构中句子逐字串行处理的限制。与传统模型不同,Transformer 完全基于多头注意力机制,采用编码器-解码器的设计框架。

Ma 等人^[107]提出了一种基于空间和时间解耦的相对位置嵌入(RPE-STDT)模型用于行为识别。该模型通过空间 Transformer 和时间 Transformer 独立捕获时空信息。空间编码器处理同一时刻内部交互,时间编码器通过子采样策略建模跨时间交互。相对位置嵌入替代绝对位置嵌入,有效捕捉令牌序列,降低计算成本,优化行为识别性能。

针对短时间行为识别任务,Mazzia 等人^[108]提出了一种名为 AcT(action Transformer)的网络结构,如图 7 所示。AcT 基于 Transformer 模型,利用多个人体关键点检测器提取的 2D 关键点作为输入。视频序列首先通过线

性投影映射到更高维度空间,然后添加一个可训练向量作为类别标记,实现自注意力机制。最终通过分类头进行分类预测。




图7 AcT网络结构概览图

Fig.7 Overview diagram of AcT network structure

针对多尺度特征建模问题,Zhao等人^[109]提出了一种时空双多尺度变压器(STDM-Transformer)。该模型将时空多尺度分为局部和全局两个层次。在局部层面,采用新的分割策略和时空转换模块来提取和整合特征;在全局层面,设计了分层融合策略以捕捉宏观运动变化。此方法比传统单尺度方法更灵活、准确。

此外,Plizzari等人^[110]在原有Transformer网络基础上加入时空自注意力模块,提出了时间自注意力网络(ST-TR)。该方法使用Transformer自注意力机制来建模关节之间的依赖关系,结合空间和时间自注意力模块捕捉帧内和帧间关系。Qiu等人^[111]提出了一种新的时空元组变压器(STTFormer)方法用于骨架行为识别。STTFormer将骨架序列分为多个部分,并利用间隔时间元组自注意模块和特征聚合模块捕捉帧间不同关节的相关性。

基于骨骼的行为识别旨在通过人体关节坐标预测动作,但传统方法如Transformer在捕捉骨骼连通性方面存在不足。Zhou等人^[112]提出了一种新的自注意扩展,称为超图自注意(HyperSA),并采用K-hop相对位置嵌入方法考虑骨骼连通性。

针对传统GCN未能捕捉身体关节间高阶依赖的问题,Wang等人^[113]提出了使用超图捕捉高阶运动模式。结合高阶变换器和两个池化模块的多阶多模变换器(3Mformer),使模型能够学习超边和时序块模式的聚合,在骨骼行为识别中表现出色。

Transformer模型通过自注意力机制可以捕捉全局

依赖关系,解决了RNN和CNN在处理长序列和全局特征提取上的不足。然而,Transformer模型的计算复杂度较高,尤其是在处理高维骨骼数据时,训练成本显著增加。虽然多尺度Transformer和高效自注意力机制在一定程度上降低了计算复杂度,但这些方法在实际应用中仍需进一步优化。

3.3.5 基于混合神经网络的方法

每种数据模态都有其特性带来的优缺点,例如,虽然RGB模态数据易于采集,但其鲁棒性较差。因此,提出了混合神经网络(hybrid neural network)的方法,以克服单模态存在的问题。

Gupta等人^[114]提出了SDL-Net模型,该模型基于CNN架构,将视频序列转换为骨骼表示,从而生成步态能量图像,并利用LSTM捕捉时序模式和收集时序数据。Zhao等人^[115]提出了一种基于改进的融合注意力CNN和RNN的网络模型,用于视频中的行为识别。该网络在特征提取和类预测阶段中采用了改进的p-非局部运算和融合无键注意力,可以更好地捕捉长期依赖关系并学习数据的序列特性。

Yang等人^[116]针对GCN在通道共享邻接矩阵时难以准确拟合复杂关节间相关性以及忽视帧间不同关节间依赖关系的问题,设计了一个混合神经网络(Hybrid-Net),该网络集成了GCN和CNN。HybridNet利用CNN同时建立时空补丁中所有点之间的相互依赖关系,并通过不同内核在通道间建模复杂依赖关系。Liu等人^[117]提出了一种新型双流异构网络,结合GCN和CNN进行行为识别。该模型中GCN处理骨骼序列,CNN处理RGB视频,并通过判别规范相关分析(DCCA)融合两者特征,以提高性能。Yang等人^[118]提出了STB-Former模型,该模型在GCN架构的基础上,采用Transformer中的自注意力机制在时间和空间维度上分别对骨架序列进行建模,以克服GCN在处理时间连续骨骼信息时的局限性。

针对基于骨架的行为识别中长期时间依赖和感受野限制的问题,Kong等人^[119]提出了多尺度时间转换器(MTT)。MTT结合了GCN和多尺度时间嵌入模块(MT-EMs),以提取多尺度特征。同时,引入了变压器编码器(TE)和任务导向横向连接(LaC),以模拟长期时间模式并对齐语义层次结构。

基于混合神经网络的方法结合了RNN、CNN、GCN和Transformer等模型的优势,构建了更为复杂和强大的模型框架,能够有效地处理骨骼数据的时空特征。然而,混合神经网络模型的结构复杂,训练和调试难度较大,对计算资源的需求也更高。尽管如此,这些方法在骨骼数据的人类行为识别中展示了良好的性能,但在模型的可解释性和实际应用中的效率方面仍然需要改进。

4 深度学习的前沿研究方向

在深度学习领域,前沿研究主要集中在提升模型的泛化能力、效率和适应性。本文将介绍三个关键方向:最新图像超分辨率算法的进展,自监督学习技术的创新及其对图像处理的影响,以及元学习在图像超分辨率中的应用与挑战。这些方向代表了当前的研究热点,并推动了技术的进一步发展。

4.1 自监督学习方法

自监督学习在人体行为识别领域展现出独特优势,特别是在数据标注成本高昂的情况下。通过设计自监督任务,模型可以从未标注的视频数据中学习有效的行为特征。Zheng 等人^[120]首次提出通过自监督学习来捕捉骨架序列中的长期全局运动动态。他们使用生成式对抗网络(GAN)的编码器-解码器架构,以骨架补全任务为基础,学习了固定维度的特征表示,并在此之上加入分类层,以实现行为识别。Yang 等人^[121]将骨架序列表示为三维骨架云,并设计了一种基于空间和时间颜色标签的自监督学习方法。通过对骨架云中的每个点进行着色,他们利用这些颜色标签生成自监督信号,有效地学习了骨架动作的表征。现有的大多数方法主要从视频的自然时空特性出发,侧重于从视觉角度提取动作表征,但往往忽略了语义信息的探索。为此,Lin 等人^[122]提出了一种新颖的自监督干扰视频动作识别方法 VARD,该方法通过共同抵抗视觉和语义干扰,无须光流、接口任务和负样本,从视觉和语义两个角度提取动作的核心信息。

自监督学习在人体行为识别和动作识别中具有显著优点,如减少对标注数据的依赖、提高特征表示能力以及较强的适应性。然而,它也存在一些挑战,包括任务设计的复杂性、训练过程中的难度、在某些情况下可能不如监督学习的性能表现,以及对数据质量的敏感性。

4.2 元学习方法

元学习在人体行为识别中的应用主要集中在提高模型在少样本场景中的泛化能力和适应性。通过学习“如何学习”,元学习模型可以在少量训练数据上快速适应新任务或新环境,这在传统数据密集型方法中是难以实现的。Lin 等人^[123]提出了一种创新的元对比网络(MCN),专注于通过元学习(MAML)的多任务机制,显著提升对比学习的泛化能力。MCN在结合元学习后,不仅解决了因类别信息缺失导致的硬性问题,还增强了对比自监督视频学习在下游任务中的适应性和表现力。Coskun 等人^[124]提出了一种结合元学习与注意力机制的 A-MAML 方法,旨在提升少样本条件下的第一人称人体行为识别。A-MAML 通过整合手部检测、抓握类型和光流特征,在有限样本下实现了更准确的行为识别和更强的迁移能力。Ding 等人^[125]提出了 RF-Net,一

种基于元学习的 RF-HAR 方法,通过双路径网络学习 RF 特征,并结合基于度量的元学习框架,减少标记工作量,提升无设备人体行为识别的适应性。

元学习在人体行为识别中的优势在于其能够在少量标记数据的情况下快速适应新任务,显著提升模型的泛化能力和迁移性,适用于数据稀缺或标注成本高的场景。然而,元学习方法的复杂性和计算成本较高,对任务选择和设计敏感,并且在大规模数据集上可能不如传统方法有效,这些都限制了其应用的广泛性。

5 实验性能对比分析

在评估基于 RGB 数据模态的算法时,通常选用经典的 HMDB51 和 UCF101 数据集作为参考标准。本文将在这两个数据集上进行算法准确率的对比,并在规模更大的 Kinetics-400 数据集上进行部分算法的对比。

表 5 统计了部分基于 RGB 数据的深度学习算法在不同数据集上的准确率对比。Two-stream CNN 方法中的 Two-stream CNN+SVM 在 2014 年于 UCF101 数据集上取得了 88.0% 的高准确率,但在 HMDB51 数据集上的准确率较低,仅为 59.4%,显示出其对不同数据集的适应性差异。TSN 通过引入时序网络,在 UCF101 上达到了 94.2% 的准确率,但在 HMDB51 上的表现稍逊,准确率为 69.4%。

在 RNN 方法中,LRCNs 在 UCF101 上表现优异,准确率达到 82.7%,其优势在于有效处理时序数据,能够捕捉动作序列中的时间依赖性。DB-LSTM 则在 UCF101 上取得了 97.3% 的高准确率,并在 HMDB51 上获得 81.2%,展现了其在复杂动作识别中的强大性能,这主要得益于其双向处理机制,能够更全面地理解动作的前后关系。相较而言,Soft attention model 在 HMDB51 数据集上的表现一般,准确率仅为 41.3%,主要由于其对背景噪声的敏感性,难以从复杂场景中提取有用特征。然而,在 Hollywood2 数据集上,该模型的准确率提升至 43.9%,显示出其在处理叙事性较强的电影场景时的应用潜力。Wu 等人^[50]的方法在 UCF101 上达到 91.3% 的准确率,并在 CCV 数据集上获得 83.5%,这表明其在不同数据集之间具有良好的适应性和稳定性,得益于结合多种特征提取策略,增强了模型对不同类型数据的泛化能力。

在 3D CNN 方法中,Two-stream I3D 在 UCF101 上取得了 97.9% 的高准确率,并在 HMDB51 上达到 80.2%,表明其能够有效捕捉时序和空间特征。最新的 TPNLST-ResCNN 在 UCF101 上表现尤为突出,达到了 98.3% 的准确率,显示了其在复杂视频分析中的优势。CT-Net 在 Kinetics-400 数据集上表现出色,取得了 79.8% 的准确率,并在 Mini-Kinetics 数据集上达到 78.0%,展现了其处理长时间序列视频的能力。然而,在更具挑战性的

表5 部分基于RGB数据的深度学习算法性能对比

Table 5 Performance comparison of some deep learning algorithms based on RGB data

Category	Methodology	Year	准确率/%			
			UCF101	HMDB51	Kinetics-400	Others
Two-Stream 2D CNN	Two-stream CNN+SVM	2014	88.0	59.4	—	—
	Multiresolution CNN	2014	65.4	—	—	—
	TSN	2016	94.2	69.4	—	—
	Bilen et al.	2017	96.0	74.9	—	—
	MSMM-ResNets	2021	93.5	66.7	—	—
RNN	LRCNs	2015	82.7	—	—	—
	Soft attention model	2015	—	41.3	—	43.9(Hollywood2)
	Wu et al.	2015	91.3	—	—	83.5(CCV)
	Meng et al.	2018	87.1	53.1	—	—
	iDT(FV)+Objects+VideoLSTM	2018	92.2	64.9	—	—
	STS-ALSTM	2020	92.7	64.4	—	—
	DB-LSTM	2021	97.3	81.2	—	—
3D CNN	JI et al.	2012	—	—	—	90.2(KTH)
	LDC+IDT	2016	92.7	67.2	—	—
	Two-stream I3D	2017	97.9	80.2	—	—
	P3D ResNet+iDT	2017	93.7	—	—	—
	ECO_En	2018	94.8	72.4	70.0	49.5(Something-Something-v1)
	TSM	2019	91.7	64.7	70.6	52.6(Something-Something-v1)
						66.0(Something-Something-v2)
	CIDC(I3D-NL)	2020	97.9	75.2	75.6	—
	SlowFast+RMS	2020	—	—	76.3	78.6(Mini-Kinetics)
						77.6(Something-Something-v2)
						97.1(Jester)
	ACTION-Net	2021	—	—	—	94.4(EgoGesture)
						64.0(Something-Something-v2)
						78.0(Mini-Kinetics)
	CT-Net	2021	96.2	73.2	79.8	56.6(Something-Something-v1)
						67.8(Something-Something-v2)
	TPNLST-ResCNN	2024	98.3	74.6	—	—

Something-Something-v1 和 v2 数据集上,CT-Net的准确率分别为 56.6%和 67.8%,反映出该模型在复杂动态场景中的局限性。与此同时,ACTION-Net在EgoGesture和Jester数据集上的表现优异,准确率分别为94.4%和97.1%,展现了其在手势识别中的强大潜力,主要得益于其对时空特征的深度挖掘。然而,在Something-Something-v2数据集上,ACTION-Net的准确率仅为64.0%,显示出该数据集的复杂性对模型的挑战。因此,尽管 ACTION-Net在特定任务中表现突出,但在更复杂场景中仍需进一步优化。

综上所述,这些方法在不同数据集上的优异表现充分反映了它们各自的特长和适用性。例如,Two-stream I3D 和 TPNLST-ResCNN 在 UCF101 和 HMDB51 数据集上的表现最为突出,说明它们能够有效捕捉复杂动作的时空特征,尤其适合处理复杂动作识别任务。CT-Net 在 Kinetics-400 和 Mini-Kinetics 数据集上的高准确率,展现了其在大规模视频数据集和长时间序列处理中的显著优势,尤其是在 Something-Something 数据集上的表现,

进一步突显了其在动态场景中的卓越性能。DB-LSTM 在 UCF101 和 HMDB51 数据集上的表现同样优异,验证了其在复杂动作分类中的高效性和强大性能。

在基于骨骼模态的算法评估中,NTU RGB+D 60 和 NTU RGB+D 120 为最常用的评估数据集,前者根据设置不同划分为 X-Sub 和 X-View 两类数据集;后者根据设置不同划分为 X-Sub 和 X-Set 两类数据集。此外,本文还在 Kinetics-Skeleton 数据集上进行少量算法的对比,并根据设置不同分为 Top1 和 Top5 两类数据集。

表6展示了部分基于骨骼数据的深度学习算法在不同数据集下的精确率对比。首先,RNN 类方法如 RNN+CNN+Attention 和 IndRNN,通过结合 RNN、CNN 和 Attention 机制,显著提升了动作识别的准确性。其中,RNN+CNN+Attention 在 NTU RGB+D 数据集的 X-Sub 和 X-View 上的准确率分别为 82.7%和 93.2%,而 IndRNN 的表现分别为 84.3%和 89.7%。尽管这些方法在处理时序信息和空间特征方面取得了突破,但在应对高动态复杂动作和长时间序列时仍存在一定的局限性。

表6 部分基于骨骼数据的深度学习算法性能对比

Table 6 Performance comparison of some deep learning algorithms based on skeletal data

Category	Methodology	Year	准确率/%					
			NTU RGB+D		NTU RGB+D 120		Kinetics-Skeleton	
			X-Sub	X-View	X-Sub	X-Set	Top1	Top5
RNN	HBRNN	2015	59.1	64.0	—	—	—	—
	dRNN	2015	—	—	—	—	—	—
	ST-LSTM	2016	69.2	77.7	—	—	—	—
	Two-stream RNN	2017	71.3	79.5	—	—	—	—
	Ensemble TS-LSTM	2017	74.6	81.3	—	—	—	—
	GCA-LSTM	2017	74.4	82.8	—	—	—	—
	RNN+CNN+Attention	2018	82.7	93.2	—	—	—	—
	IndRNN	2022	84.3	89.7	—	—	—	—
	CNN-TS LSTM	2023	87.9	92.5	—	—	37.8	59.8
CNN	Two-stream ConvNets.	2014	—	—	—	—	—	—
	JTM	2016	73.4	75.2	—	—	—	—
	CNN+Motion+Trans	2017	83.2	89.3	—	—	—	—
	SkeletonNet	2017	75.9	81.2	—	—	—	—
	Proposed method	2017	85.0	92.3	—	—	—	—
	Proposed HCN	2018	86.5	91.1	—	—	—	—
	SkeleMotion	2019	76.5	84.7	67.7	66.9	—	—
	Fuzzy integral	2020	84.2	89.7	74.8	76.9	—	—
	FO-GASTM	2023	90.0	91.3	—	—	—	—
GCN	梁成武等	2024	93.8	96.9	86.6	89.9	—	—
	ST-GCNT	2018	81.5	88.3	70.7	73.2	30.7	52.8
	AS-GCN	2019	86.8	94.2	77.9	78.5	34.8	56.5
	2s-AGCN	2019	88.5	95.1	82.5	84.2	36.1	58.7
	MSAAGCN	2022	90.9	95.9	87.1	87.9	37.7	60.4
	Shift-GCN	2020	90.7	96.5	85.9	87.6	—	—
	MS-G3D	2020	91.5	96.2	86.9	88.4	38.0	60.9
	CTR-GCN	2021	92.4	96.8	91.2	96.0	—	—
	MST-GCN	2021	91.5	96.6	87.5	88.8	38.1	60.8
	MKE-GCN	2022	92.4	96.7	89.5	90.8	—	—
	TFC-GCN	2023	87.9	91.5	83.0	81.6	—	—
	MM-GCN	2023	90.8	95.2	86.3	87.5	—	—
	EfficientGCN	2023	92.1	96.1	88.7	88.9	—	—
	LMA-GCN	2024	88.2	95.0	83.2	84.1	—	—
Transformer	ST-TR	2021	89.9	96.1	82.7	84.7	—	—
	Hyperformer	2022	92.9	96.5	89.9	91.3	—	—
	STTFormer	2022	92.3	96.5	88.3	89.2	—	—
	STDm-Transformer	2023	92.6	96.4	88.9	90.8	—	—
	3Mformer	2023	94.8	98.7	92.0	93.8	48.3	72.3
Hybrid neural network	DCCA Fusion	2021	95.9	98.7	—	—	—	—
	STB-Former	2022	92.0	96.2	87.1	88.6	—	—
	MTT	2022	96.7	90.8	86.1	87.6	37.9	61.3
	HybridNet	2023	91.4	96.9	87.5	89.0	—	—

其次,CNN类方法如CNN+Motion+Trans和Proposed method,通过融合运动信息和转换机制,进一步提升了识别的准确率。具体而言,CNN+Motion+Trans在NTU RGB+D数据集上取得了83.2%(X-Sub)和89.3%(X-View)的准确率,而Proposed method则达到了85.0%(X-Sub)和92.3%(X-View)。尽管这些方法在准确率方面表现优异,但在处理数据不均衡和噪声问题上仍面临挑战。目

前,表现最优的方法为梁成武等人提出的方案,其在NTU RGB+D数据集上的准确率分别达到了93.8%(X-Sub)和96.9%(X-View),而在NTU RGB+D 120数据集上则为86.6%(X-Sub)和89.9%(X-Set)。

此外,GCN类方法如AS-GCN和2s-AGCN,通过改进GCN,增强了对骨架数据空间关系的处理能力。AS-GCN在NTU RGB+D数据集上的准确率为86.8%

(X-Sub)和94.2%(X-View),而2s-AGCN的表现则分别为88.5%和95.1%。在Kinetics-Skeleton数据集上,其Top1准确率为36.1%。虽然这些方法表现强劲,但在处理大规模数据集时,计算复杂度较高。

最后,Transformer类方法如Hyperformer和3Mformer,通过自注意力机制有效捕捉全局信息,取得了显著提升。Hyperformer在NTU RGB+D数据集上的准确率为92.9%(X-Sub)和96.5%(X-View),而3Mformer的表现更为优异,分别达到了94.8%和98.7%。尽管这些方法性能突出,但其高计算资源需求可能限制其在实际应用中的推广。

此外,在Hybrid neural network中,DCCA Fusion和MTT通过融合多种特征和模型,进一步提升了动作识别性能。DCCA Fusion在NTU RGB+D数据集上的准确率达到了95.9%(X-Sub)和98.7%(X-View),而MTT在X-Sub上的准确率为96.7%。

总的来说,这些深度学习方法在骨架动作识别领域各自展现了独特的优势。例如,GCN类方法在处理空间关系上表现出色,而Transformer类方法则在捕捉全局信息方面尤为突出。同时,Hybrid neural network通过融合多种特征和模型,进一步提升了整体性能。这些方法的成功应用表明,结合多种机制和模型架构是提升骨架动作识别性能的有效途径。

6 展望

综上所述,基于RGB和骨骼数据的人体行为识别方法已取得显著的研究成果,并在多个领域展现出广阔的应用前景。然而,该领域的研究仍存在许多值得深入探索的方向。基于对现有方法的系统总结,本文展望了未来的研究发展方向。

6.1 深度融合与协同学习

当前的行为识别研究多集中在单一模态的数据分析上,多模态数据的深度融合研究较为缺乏。未来的研究应重点探索如何通过整合不同模态的数据,如RGB、骨骼和深度图像等,以提高行为识别的准确性和鲁棒性。特别是在处理复杂行为和多样化场景时,协同学习方法将成为关键,这种方法可以在各模态数据共享信息的同时,保留其独特的特性,从而增强模型捕捉行为细微差异的能力。深入研究多模态融合将成为提升行为识别性能的关键所在。

6.2 动态环境适应与鲁棒性增强

现有的行为识别系统在应对动态变化的环境时表现出鲁棒性不足,尤其是在光照变化、遮挡以及摄像机角度变化等情况下,其性能显著下降。未来的研究应集中在开发自适应模型上,使其能够在训练和实际应用中自动调整参数,以适应不同环境的变化。此外,还需要引入鲁棒性增强技术,通过集成域自适应、对抗性训练

等优化算法,提高模型的稳定性和抗干扰能力,从而确保在复杂且多变的应用场景中依然保持高识别精度。

6.3 大规模无监督学习与迁移学习

尽管深度学习在行为识别中表现出色,但其对大量标注数据的依赖成为一个显著瓶颈,尤其是在新场景或新任务中。未来的研究应重点关注大规模无监督学习与迁移学习的结合,旨在开发能够在少量或无标注数据情况下依然保持高性能的行为识别模型。通过无监督学习挖掘数据的潜在结构,并结合迁移学习从其他领域迁移知识,可以显著降低对标注数据的依赖,同时提升模型在新场景中的适应能力和泛化能力。这种方法在资源受限场景中的应用前景广阔。

6.4 实时性与计算效率的提升

随着行为识别应用场景的不断扩展,实时性和计算效率的问题变得愈发重要。虽然现有的深度学习模型在精度上有所突破,但高计算复杂度和资源消耗限制了其在实时应用中的推广。未来的研究应致力于设计轻量级模型和优化算法,开发适用于移动设备和嵌入式系统等资源受限设备的高效解决方案。同时,还应探索专用硬件加速器的应用,进一步提高行为识别系统的处理速度,以满足实际应用中对实时性和低功耗的高要求。

6.5 隐私保护与数据安全

随着人体行为识别技术的广泛应用,隐私保护和伦理问题日益受到关注。未来的研究不仅需要在技术上取得突破,还必须深入探讨行为识别技术在不同应用场景下的隐私保护和伦理风险。尤其是在涉及个人敏感数据的场景中,如何通过联邦学习和差分隐私等技术手段保障用户隐私,同时在数据使用过程中严格遵循伦理规范,将成为未来研究的重点。此外,还应加强与法律法规的配套研究,以确保行为识别技术的可持续发展。

参考文献:

[1] ALNUAIM A A, ZAKARIAH M, SHUKLA P K, et al. Human-computer interaction for recognizing speech emotions using multilayer perceptron classifier[J]. Journal of Healthcare Engineering, 2022, 2022(1): 6005446.

[2] 张毅, 黄聪, 罗元. 基于改进朴素贝叶斯分类器的康复训练行为识别方法[J]. 计算机应用, 2013, 33(11): 3187-3189.

ZHANG Y, HUANG C, LUO Y. Behavior recognition in rehabilitation training based on modified naive Bayes classifier[J]. Journal of Computer Applications, 2013, 33(11): 3187-3189.

[3] 刘延伟, 黄志明, 高博麟, 等. 车载视角下基于视觉信息的前车行为识别[J]. 汽车安全与节能学报, 2023, 14(6): 707-714.

LIU Y W, HUANG Z M, GAO B L, et al. Recognition of front vehicle behavior based on visual information from vehicle perspective[J]. Journal of Automotive Safety and Energy,

- 2023, 14(6): 707-714.
- [4] RAHMANI H, BENNAMOUN M, KE Q. Human action recognition from various data modalities: a review[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 45(3): 3200-3225.
- [5] REN B, LIU M, DING R, et al. A survey on 3D skeleton-based action recognition using learning method[J]. arXiv: 2002.05907, 2020.
- [6] 黄倩, 崔静雯, 李畅. 基于骨骼的人体行为识别方法研究综述[J]. 计算机辅助设计与图形学学报, 2024, 36(2): 173-194.
- HUANG Q, CUI J W, LI C. A review of skeleton-based human action recognition[J]. Journal of Computer-Aided Design & Computer Graphics, 2024, 36(2): 173-194.
- [7] 卢健, 李萱峰, 赵博, 等. 骨骼信息的人体行为识别综述[J]. 中国图象图形学报, 2023, 28(12): 3651-3669.
- LU J, LI X F, ZHAO B, et al. A review of skeleton-based human action recognition[J]. Journal of Image and Graphics, 2023, 28(12): 3651-3669.
- [8] NI W C, ZHANG B T, ZHANG J T, et al. Target perception and behavioral recognition algorithms based on saliency and feature extraction[J]. IEEE Access, 2023, 12: 6790-6798.
- [9] XU J K, PAN C. Human behavior recognition based on attention mechanism and bottleneck residual dual-path spatiotemporal graph convolutional network[C]//Proceedings of the 4th International Conference on Neural Networks, Information and Communication Engineering, 2024: 807-812.
- [10] ZHENG P F, ZHANG A X, CHEN J Z, et al. Real-time fall recognition using a lightweight convolution neural network based on millimeter-wave radar[J]. IEEE Sensors Journal, 2024, 24(5): 7185-7195.
- [11] KUEHNE H, JHUANG H, STIEFELHAGEN R, et al. HMDB51: a large video database for human motion recognition[C]//Proceedings of the High Performance Computing in Science and Engineering, 2013: 571-582.
- [12] SOOMRO K, ZAMIR A, SHAH M. UCF101: a dataset of 101 human actions classes from videos in the wild[J]. arXiv: 1212.0402, 2012.
- [13] REDDY K K, SHAH M. Recognizing 50 human action categories of web videos[J]. Machine Vision and Applications, 2013, 24(5): 971-981.
- [14] KAY W, CARREIRA J, SIMONYAN K, et al. The Kinetics human action video dataset[J]. arXiv:1705.06950, 2017.
- [15] CARREIRA J, NOLAND E, BANKI-HORVATH A, et al. A short note about Kinetics-600[J]. arXiv:1808.01340, 2018.
- [16] CARREIRA J, NOLAND E, HILLIER C, et al. A short note on the Kinetics-700 human action dataset[J]. arXiv:1907.06987, 2019.
- [17] GOYAL R, KAHOU S E, MICHALSKI V, et al. The "Something Something" video database for learning and evaluating visual common sense[C]//Proceedings of the 2017 IEEE International Conference on Computer Vision, 2017: 5843-5851.
- [18] DAMEN D M, DOUGHTY H, FARINELLA G M, et al. Scaling egocentric vision: the EQIC-KITCHENS dataset[J]. arXiv:1804.02748, 2018.
- [19] HEILBRON F C, ESCORCIA V, GHANEM B, et al. ActivityNet: a large-scale video benchmark for human activity understanding[C]//Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition, 2015: 961-970.
- [20] SUNG J, PONCE C, SELMAN B, et al. Human activity detection from RGBD images[C]//Proceedings of the 16th AAAI Conference on Plan, Activity, and Intent Recognition, 2011: 47-55.
- [21] KOPPULA H S, GUPTA R, SAXENA A. Learning human activities and object affordances from RGB-D videos[J]. International Journal of Robotics Research, 2013, 32(8): 951-970.
- [22] LIU Z, ZHANG C Y, TIAN Y L. 3D-based deep convolutional neural network for action recognition with depth sequences[J]. Image and Vision Computing, 2016, 55: 93-100.
- [23] SHAHROUDY A, LIU J, NG T T, et al. NTU RGB+D: a large scale dataset for 3D human activity analysis[C]//Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1010-1019.
- [24] LIU J, SHAHROUDY A, PEREZ M, et al. NTU RGB+D 120: a large-scale benchmark for 3D human activity understanding[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(10): 2684-2701.
- [25] LI W Q, ZHANG Z Y, LIU Z C. Action recognition based on a bag of 3D points[C]//Proceedings of the 2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2010: 9-14.
- [26] WANG J, LIU Z C, WU Y, et al. Mining actionlet ensemble for action recognition with depth cameras[C]//Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition, 2012: 1290-1297.
- [27] YAN S J, XIONG Y J, LIN D H. Spatial temporal graph convolutional networks for skeleton-based action recognition[C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence and 30th Innovative Applications of Artificial Intelligence Conference and 8th AAAI Symposium on Educational Advances in Artificial Intelligence, 2018: 7444-7452.
- [28] HU J F, ZHENG W S, LAI J H, et al. Jointly learning heterogeneous features for RGB-D activity recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(11): 2186-2200.
- [29] WANG J, NIE X H, XIA Y, et al. Cross-view action modeling, learning, and recognition[C]//Proceedings of the IEEE

- Conference on Computer Vision and Pattern Recognition, 2014: 2649-2656.
- [30] RAHMANI H, MAHMOOD A, HUYNH D, et al. Histogram of oriented principal components for cross-view action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(12): 2430-2443.
- [31] BOBICK A F, DAVIS J W. The recognition of human movement using temporal templates[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2001, 23(3): 257-267.
- [32] DAVIS J W, BOBICK A F. The representation and recognition of human movement using temporal templates[C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 1997: 928-934.
- [33] WANG H, ULLAH M M, KLÄSER A, et al. Evaluation of local spatio-temporal features for action recognition[C]//Proceedings of the British Machine Vision Conference, 2009.
- [34] EVERTS I, GEMERT V J C, GEVERS T. Evaluation of color spatio-temporal interest points for human action recognition[J]. IEEE Transactions on Image Processing, 2014, 23(4): 1569-1580.
- [35] ZHU Y, CHEN W B, GUO G D. Evaluating spatiotemporal interest point features for depth-based action recognition[J]. Image and Vision Computing, 2014, 32(8): 453-464.
- [36] WANG H, KLÄSER A, SCHMID C, et al. Dense trajectories and motion boundary descriptors for action recognition [J]. International Journal of Computer Vision, 2013, 103(1): 60-79.
- [37] WANG H, KLÄSER A, SCHMID C, et al. Action recognition by dense trajectories[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2011: 3169-3176.
- [38] VIG E, DORR M, COX D. Space-variant descriptor sampling for action recognition based on saliency and eye movements[C]//Proceedings of the European Conference on Computer Vision, 2012: 84-97.
- [39] SIMONYAN K, ZISSERMAN A, SIMONYAN K, et al. Two-stream convolutional networks for action recognition in videos[C]//Proceedings of the 28th International Conference on Neural Information Processing Systems, 2014: 568-576.
- [40] KARPATY A, TODERICI G, SHETTY S, et al. Large-scale video classification with convolutional neural networks[C]//Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition, 2014: 1725-1732.
- [41] ZONG M, WANG R L, CHEN X B, et al. Motion saliency based multi-stream multiplier ResNets for action recognition[J]. Image and Vision Computing, 2021, 107: 104108.
- [42] BILEN H, FERNANDO B, GAVVES E, et al. Action recognition with dynamic image networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(12): 2799-2813.
- [43] WANG L M, XIONG Y J, WANG Z, et al. Temporal segment networks: towards good practices for deep action recognition[J]. arXiv:1608.00859, 2016.
- [44] DONAHUE J, HENDRICKS L A, ROHRBACH M, et al. Long-term recurrent convolutional networks for visual recognition and description[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(4): 677-691.
- [45] HE J Y, WU X, CHENG Z Q, et al. DB-LSTM: densely-connected bi-directional LSTM for human action recognition[J]. Neurocomputing, 2021, 444: 319-331.
- [46] SHARMA S, KIROS R, SALAKHUTDINOV R. Action recognition using visual attention[J]. arXiv:1511.04119, 2015.
- [47] MENG L L, ZHAO B, CHANG B, et al. Interpretable spatio-temporal attention for video action recognition[C]//Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision Workshop, 2019: 1513-1522.
- [48] LI Z Y, GAVRILYUK K, GAVVES E, et al. VideoLSTM convolves, attends and flows for action recognition[J]. Computer Vision and Image Understanding, 2018, 166: 41-50.
- [49] LIU Z B, LI Z Y, WANG R L, et al. Spatiotemporal saliency-based multi-stream networks with attention-aware LSTM for action recognition[J]. Neural Computing and Applications, 2020, 32(18): 14593-14602.
- [50] WU Z X, WANG X, JIANG Y G, et al. Modeling spatial-temporal clues in a hybrid deep learning framework for video classification[C]//Proceedings of the 23rd ACM International Conference on Multimedia, 2015: 461-470.
- [51] JI S W, XU W, YANG M, et al. 3D convolutional neural networks for human action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(1): 221-231.
- [52] ZOLFAGHARI M, SINGH K, BROX T. ECO: efficient convolutional network for online video understanding[J]. arXiv:1804.09066, 2018.
- [53] VAROL G, LAPTEV I, SCHMID C. Long-term temporal convolutions for action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(6): 1510-1517.
- [54] LI X Y, SHUAI B, TIGHE J. Directional temporal modeling for action recognition[J]. arXiv:2007.11040, 2020.
- [55] CARREIRA J, ZISSERMAN A. Quo vadis, action recognition? a new model and the kinetics dataset[C]//Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4724-4733.
- [56] QIU Z F, YAO T, MEI T. Learning spatio-temporal representation with pseudo-3D residual networks[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 5534-5542.

- [57] LIN J, GAN C, HAN S. TSM: temporal shift module for efficient video understanding[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 7082-7092.
- [58] WANG Z W, SHE Q, SMOLIC A. ACTION-Net: multipath excitation for action recognition[J]. arXiv:2103.07372, 2021.
- [59] KIM J, CHA S, WEE D, et al. Regularization on spatio-temporally smoothed feature for action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 12100-12109.
- [60] LI K C, LI X H, WANG Y, et al. CT-Net: channel tensorization network for video classification[J]. arXiv:2106.01603, 2021.
- [61] 钱惠敏, 陈实, 皇甫晓璞. 基于双流-非局部时空残差卷积神经网络的人体行为识别[J]. 电子与信息学报, 2024, 46(3): 1100-1108.
- QIAN H M, CHEN S, HUANGFU X Y. Human activities recognition based on two-stream NonLocal spatial temporal residual convolution neural network[J]. Journal of Electronics & Information Technology, 2024, 46(3): 1100-1108.
- [62] FANG H S, LI J F, TANG H Y, et al. AlphaPose: whole-body regional multi-person pose estimation and tracking in real-time[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(6): 7157-7173.
- [63] LYU X Y, WANG S Y, CHEN T, et al. Human gait analysis method based on sample entropy fusion AlphaPose algorithm[C]//Proceedings of the 33rd Chinese Control and Decision Conference, 2021: 1543-1547.
- [64] YANG J K, HE Y Q, ZHU J X, et al. Fall detection method for infrared videos based on spatial-temporal graph convolutional network[J]. Sensors, 2024, 24(14): 4647.
- [65] CAO Z, SIMON T, WEI S H, et al. Realtime multi-person 2D pose estimation using part affinity fields[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1302-1310.
- [66] LIU H C, MEI J Q, JIA F, et al. AuraPose: accurate human pose detection and behavior recognition via enhanced OpenPose with angular measurement[C]//Proceedings of the IEEE International Instrumentation and Measurement Technology Conference, 2024: 1-6.
- [67] CHEN Y Y, ZHANG J, WANG Y L. Human action recognition and analysis methods based on OpenPose and deep learning[C]//Proceedings of the International Conference on Integrated Circuits and Communication Systems, 2024: 1-5.
- [68] JHUANG H, GALL J, ZUFFI S, et al. Towards understanding action recognition[C]//Proceedings of the IEEE International Conference on Computer Vision, 2013: 3192-3199.
- [69] HUSSEIN M E, TORKI M, GOWAYYED M A, et al. Human action recognition using a temporal hierarchy of covariance descriptors on 3D joint locations[C]//Proceedings of the 23rd International Joint Conference on Artificial Intelligence, 2013: 2466-2472.
- [70] ZHOU Q Y, YU S Q, WU X Y, et al. HMMs-based human action recognition for an intelligent household surveillance robot[C]//Proceedings of the IEEE International Conference on Robotics and Biomimetics, 2009: 2295-2300.
- [71] YOU Y X, LIU H, WANG T, et al. Co-evolution of pose and mesh for 3D human body estimation from video[C]//Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision, 2023: 14917-14927.
- [72] CHAUDHRY R, OFLI F, KURILLO G, et al. Bio-inspired dynamic 3D discriminative skeletal features for human action recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2013: 471-478.
- [73] DU Y, WANG W, WANG L. Hierarchical recurrent neural network for skeleton based action recognition[C]//Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1110-1118.
- [74] LI W B, WEN L Y, CHANG M C, et al. Adaptive RNN tree for large-scale human action recognition[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 1453-1461.
- [75] WANG H S, WANG L. Modeling temporal dynamics and spatial configurations of actions using two-stream recurrent neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3633-3642.
- [76] LIU J, SHAHROUDY A, XU D, et al. Spatio-temporal LSTM with trust gates for 3D human action recognition[J]. arXiv: 1607.07043, 2016.
- [77] VEERIAH V, ZHUANG N F, QI G J. Differential recurrent neural networks for action recognition[C]//Proceedings of the IEEE International Conference on Computer Vision, 2015: 4041-4049.
- [78] LEE I, KIM D, KANG S, et al. Ensemble deep learning for skeleton-based action recognition using temporal sliding LSTM networks[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 1012-1020.
- [79] LI C, XIE C Y, ZHANG B C, et al. Memory attention networks for skeleton-based action recognition[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(9): 4800-4814.
- [80] LIU J, WANG G, HU P, et al. Global context-aware attention LSTM networks for 3D action recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3671-3680.
- [81] GAO Y B, LI C K, LI S, et al. Variable rate independently recurrent neural network (IndRNN) for action recognition[J]. Applied Sciences, 2022, 12(7): 3281.
- [82] 高治军, 顾巧瑜, 陈平, 等. 基于CNN-LSTM双流融合网络

- 的危险行为识别[J]. 数据采集与处理, 2023, 38(1): 132-140.
- GAO Z J, GU Q Y, CHEN P, et al. Dangerous behavior recognition based on CNN-LSTM dual-stream fusion network [J]. Journal of Data Acquisition and Processing, 2023, 38(1): 132-140.
- [83] LI C, ZHONG Q Y, XIE D, et al. Skeleton-based action recognition with convolutional neural networks[C]//Proceedings of the IEEE International Conference on Multimedia & Expo Workshops, 2017: 597-600.
- [84] CAETANO C, SENA J, BRÉMOND F, et al. SkeleMotion: a new representation of skeleton joint sequences based on motion information for 3D action recognition[C]//Proceedings of the 16th IEEE International Conference on Advanced Video and Signal Based Surveillance, 2019: 1-8.
- [85] KE Q H, AN S J, BENNAMOUN M, et al. SkeletonNet: mining deep part features for 3D action recognition[J]. IEEE Signal Processing Letters, 2017, 24(6): 731-735.
- [86] LI C, ZHONG Q Y, XIE D, et al. Co-occurrence feature learning from skeleton data for action recognition and detection with hierarchical aggregation[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence, 2018: 786-792.
- [87] BANERJEE A, SINGH P K, SARKAR R. Fuzzy integral-based CNN classifier fusion for 3D skeleton action recognition[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 31(6): 2206-2216.
- [88] WANG P C, LI Z Y, HOU Y H, et al. Action recognition based on joint trajectory maps using convolutional neural networks[C]//Proceedings of the 24th ACM International Conference on Multimedia, 2016: 102-106.
- [89] LI B, DAI Y C, CHENG X L, et al. Skeleton based action recognition using translation-scale invariant image mapping and multi-scale deep CNN[C]//Proceedings of the 2017 IEEE International Conference on Multimedia & Expo Workshops, 2017: 601-604.
- [90] LI Y S, XIA R J, LIU X, et al. Learning shape-motion representations from geometric algebra spatio-temporal model for skeleton-based action recognition[C]//Proceedings of the IEEE International Conference on Multimedia and Expo, 2019.
- [91] 梁成武, 杨杰, 胡伟, 等. 基于时间动态帧选择与时空图卷积的可解释骨架行为识别[J]. 图学学报, 2024, 45(4): 791-803.
- LIANG C W, YANG J, HU W, et al. Temporal dynamic frame selection and spatio-temporal graph convolution for interpretable skeleton-based action recognition[J]. Journal of Graphic, 2024, 45(4): 791-803.
- [92] 赵登阁, 智敏. 用于人体动作识别的多尺度时空图卷积算法[J]. 计算机科学与探索, 2023, 17(3): 719-732.
- ZHAO D G, ZHI M. Spatial multiple-temporal graph convolutional neural network for human action recognition[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(3): 719-732.
- [93] LI M, CHEN S, CHEN X, et al. Actional-structural graph convolutional networks for skeleton-based action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 3590-3598.
- [94] SHI L, ZHANG Y F, CHENG J, et al. Two-stream adaptive graph convolutional networks for skeleton-based action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 12018-12027.
- [95] SHI L, ZHANG Y F, CHENG J, et al. Skeleton-based action recognition with multi-stream adaptive graph convolutional networks[J]. IEEE Transactions on Image Processing, 2020, 29: 9532-9545.
- [96] CHENG K, ZHANG Y F, HE X Y, et al. Skeleton-based action recognition with shift graph convolutional network [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 180-189.
- [97] SONG Y F, ZHANG Z, SHAN C F, et al. Constructing stronger and faster baselines for skeleton-based action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(2): 1474-1488.
- [98] JIANG Y J, DENG H M. Lighter and faster: a multi-scale adaptive graph convolutional network for skeleton-based action recognition[J]. Engineering Applications of Artificial Intelligence, 2024, 132: 107957.
- [99] 王琪, 何宁. 融合内在拓扑与多尺度时间特征的骨架动作识别[J]. 计算机工程与应用, 2025, 61(4): 150-157.
- WANG Q, HE N. Skeleton action recognition by integrating intrinsic topology and multiscale time features[J]. Computer Engineering and Applications, 2025, 61(4): 150-157.
- [100] WANG K X, DENG H M. TFC-GCN: lightweight temporal feature cross-extraction graph convolutional network for skeleton-based action recognition[J]. Sensors, 2023, 23(12): 5593.
- [101] YANG S, WANG X H, GAO L L, et al. MKE-GCN: multi-modal knowledge embedded graph convolutional network for skeleton-based action recognition in the wild[C]//Proceedings of the IEEE International Conference on Multimedia and Expo, 2022: 1-6.
- [102] KANG M S, KANG D, KIM H. Efficient skeleton-based action recognition via joint-mapping strategies[C]//Proceedings of the 2023 IEEE/CVF Winter Conference on Applications of Computer Vision, 2023: 3392-3401.
- [103] LIU Z, ZHANG H, CHEN Z, et al. Disentangling and unifying graph convolutions for skeleton-based action recognition[J]. arXiv:2003.14111, 2020.
- [104] CHEN Y X, ZHANG Z Q, YUAN C F, et al. Channel-wise

- topology refinement graph convolution for skeleton-based action recognition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 13339-13348.
- [105] CHEN Z, LI S C, YANG B, et al. Multi-scale spatial temporal graph convolutional network for skeleton-based action recognition[J]. arXiv:2206.13028, 2022.
- [106] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017: 6000-6010.
- [107] MA Y J, WANG R L. Relative-position embedding based spatially and temporally decoupled Transformer for action recognition[J]. Pattern Recognition, 2024, 145: 109905.
- [108] MAZZIA V, ANGARANO S, SALVETTI F, et al. Action Transformer: a self-attention model for short-time pose-based human action recognition[J]. Pattern Recognition, 2022, 124: 108487.
- [109] ZHAO Z F, CHEN Z W, LI J N, et al. STDM-Transformer: space-time dual multi-scale transformer network for skeleton-based action recognition[J]. Neurocomputing, 2024, 563: 126903.
- [110] PLIZZARI C, CANNICI M, MATTEUCCI M. Spatial temporal transformer network for skeleton-based action recognition[C]//Proceedings of the 2021 China Automation Congress, 2021: 7029-7034.
- [111] QIU H, HOU B, REN B, et al. Spatio-temporal tuples transformer for skeleton-based action recognition[J]. arXiv: 2201.02849, 2022.
- [112] ZHOU Y, CHENG Z Q, LI C, et al. Hypergraph transformer for skeleton-based action recognition[J]. arXiv:2211.09590, 2022.
- [113] WANG L, KONIUSZ P. 3Mformer: multi-order multi-mode transformer for skeletal action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 5620-5631.
- [114] GUPTA D, SINGH A K, GUPTA N, et al. SDL-Net: a combined CNN & RNN human activity recognition model[C]// Proceedings of the International Conference in Advances in Power, Signal, and Information Technology, 2023: 1-5.
- [115] ZHAO H, JIN X Y. Human action recognition based on improved fusion attention CNN and RNN[C]//Proceedings of the 5th International Conference on Computational Intelligence and Applications, 2020: 108-112.
- [116] YANG W J, ZHANG J L, CAI J J, et al. HybridNet: integrating GCN and CNN for skeleton-based action recognition[J]. Applied Intelligence, 2023, 53(1): 574-585.
- [117] LIU K, GAO L, KHAN N M, et al. A two-stream heterogeneous network for action recognition based on skeleton and RGB modalities[C]//Proceedings of the IEEE International Symposium on Multimedia, 2021.
- [118] YANG F, LI D W, WANG G. Spatial temporal block transformer network for skeleton-based action recognition[C]// Proceedings of the China Automation Congress, 2022: 1259-1264.
- [119] KONG J, BIAN Y H, JIANG M. MTT: multi-scale temporal transformer for skeleton-based action recognition[J]. IEEE Signal Processing Letters, 2022, 29: 528-532.
- [120] ZHENG N G, WEN J, LIU R S, et al. Unsupervised representation learning with long-term dynamics for skeleton based action recognition[C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence and 31th Innovative Applications of Artificial Intelligence Conference and 8th AAAI Symposium on Educational Advances in Artificial Intelligence, 2018: 2644-2651.
- [121] YANG S Y, LIU J, LU S J, et al. Self-supervised 3D action representation learning with skeleton cloud colorization [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(1): 509-524.
- [122] LIN W, DING X H, HUANG Y, et al. Self-supervised video-based action recognition with disturbances[J]. IEEE Transactions on Image Processing, 2023, 32: 2493-2507.
- [123] LIN Y Z, GUO X, LU Y. Self-supervised video representation learning with meta-contrastive network[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 8219-8229.
- [124] COSKUN H, ZEESHAN Z M, TEKIN B, et al. Domain-specific priors and meta learning for few-shot first-person action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(6): 6659-6673.
- [125] DING S Y, CHEN Z, ZHENG T Y, et al. RF-Net: a unified meta-learning framework for RF-enabled one-shot human activity recognition[J]. arXiv:2111.04566, 2021.