

引用格式: 李宇楠, 耿熙, 苗启广. 基于计算机视觉的手语识别与翻译研究综述[J]. 微电子学与计算机, 2025, 42(6): 15-36.

LI Y N, GENG X, MIAO Q G. A review of research on computer vision-oriented sign language recognition and translation[J]. Microelectronics & Computer, 2025, 42(6): 15-36.

DOI: 10.19304/J.ISSN1000-7180.2024.0261

基于计算机视觉的手语识别与翻译研究综述

李宇楠^{1,2,3}, 耿 熙^{1,2,3}, 苗启广^{1,2,3}

(1 西安电子科技大学 计算机科学与技术学院, 陕西 西安 710071;

2 西安市大数据与视觉智能关键技术重点实验室, 陕西 西安 710071;

3 协同智能系统教育部重点实验室, 陕西 西安 710071)

摘 要: 手语动作的复杂性和多样性显著增加了学习难度, 在一定程度上阻碍了聋哑人士与健听人群之间的有效交流。随着计算机技术的发展, 为了解决非手语者与聋哑人之间无法无障碍交流的问题, 基于计算机视觉的手语识别与翻译技术应运而生。其中, 手语识别是将手语视频所表达的一个或多个手语词逐个识别, 并映射为对应的标注文本; 手语翻译则是在其基础上进一步将手语标注序列转换为符合自然语言语序的句子。手语识别与翻译任务对输入的手语视频进行视觉特征提取并捕获其上下文信息最终以文本形式输出, 是一种典型的跨学科研究。本文以手语识别与手语翻译两大任务作为论述线索, 系统地介绍了手语识别及手语翻译两类任务的发展情况及相关的各种方法。对手语识别任务分别从孤立词手语识别与连续手语识别两个方面展开, 根据各研究在特征提取、序列建模以及识别分类阶段所使用方法不同进行分类归纳并分析各自特点; 对于手语翻译任务则根据是否使用手语标注(Gloss)文本作为媒介, 分别介绍了 Sign2Text 与 Sign2Gloss2Text 两类方法的研究情况。其次, 本文还归纳整理了当前主流的不同国家地区的手语识别与翻译数据集、相应的评价指标以及在主流数据集上的先进方法。此外, 根据现有研究的优势与不足, 从相邻手语动作粘连、视频序列与标注序列对应关系缺失以及多模态数据融合等方面总结手语识别与翻译任务中现存的问题, 并对未来研究的发展方向进行展望。

关键词: 手语识别; 手语翻译; 计算机视觉; 自然语言处理

中图分类号: TP37

文献标识码: A

文章编号: 1000-7180(2025)06-0015-22

A review of research on computer vision-oriented sign language recognition and translation

LI Yunan^{1,2,3}, GENG Xi^{1,2,3}, MIAO Qiguang^{1,2,3}

(1 School of Computer Science and Technology, Xidian University, Xi'an 710071, China;

2 Xi'an Key Laboratory of Big Data and Intelligent Vision, Xi'an 710054, China;

3 Key Laboratory of Collaborative Intelligence Systems, Ministry of Education, Xi'an 710071, China)

Abstract: Sign language serves as a bridge for communication between the deaf and the hearing ones. However, the complexity and diversity of sign language gestures increase the learning cost of sign language, posing obstacles to widespread communication between deaf and hearing individuals. With the development of computer technology, computer vision-based sign language recognition and translation techniques have emerged to address the barrier-free communication issues between non-signers and deaf individuals. Sign language recognition is the process of identifying one or more sign

收稿日期: 2024-04-28; 修回日期: 2024-07-03

基金项目: 新一代人工智能国家科技重大专项(2022ZD0117103); 国家自然科学基金(62002271, 62272364); 陕西省重点研发计划(2024GH-ZDXM-47); 陕西高等继续教育教学改革研究课题(21XJZ004)

<https://www.journalmc.com>

language words in sign language videos, and mapping them to corresponding annotated text, while sign language translation further converts the Gloss sequence into sentences that follow the natural language syntax. The task of sign language recognition and translation involves extracting visual features from input sign language videos, capturing contextual information, and ultimately outputting the information in text form. It is a typical interdisciplinary research field. This article systematically introduces the development of sign language recognition and translation, and takes these two tasks as the thread of discussion. The sign language recognition task can be divided into isolated sign language recognition and continuous sign language recognition. Based on the different methods used in feature extraction, sequence modeling, and classification stages in each study, they are categorized, summarized, and analyzed according to their respective characteristics. Additionally, it explores sign language translation by introducing research on two types of methods: Sign2Text and Sign2Gloss2Text, based on whether Gloss annotations are used as a medium. Furthermore, this paper also summarizes the current mainstream sign language recognition and translation datasets from different countries and regions, the corresponding evaluation metrics, and state-of-the-art methods on widely used datasets. Finally, based on the strengths and weaknesses of existing research, the article concludes the current issues in sign language recognition and translation tasks and provides an outlook on future research directions in this field.

Key words: sign language recognition; sign language translation; computer vision; natural language processing

1 引言

手语是聋哑人之间最为重要的交流沟通方式。据世界卫生组织发布的《世界听力报告》^[1]估计,听力损失目前影响着全球超过 15 亿人,其中 4.3 亿人至少有中度及以上的听力损失。世界范围内聋哑人的基数十分庞大,占到了全球总人口的 5%。面对如此庞大的手语用户群体,手语识别与翻译相关技术的发展与应用显得尤为迫切。然而,由于绝大部分健听人从未接触过手语,且系统的学习手语需要花费极大的精力,这导致了手语翻译者的极度短缺,也给手语教学、聋哑人与健听人之间的沟通交流带来了极大的不便。因此,发展基于深度学习的手语识别技术显得尤为重要。

近年来,随着人工智能技术的高速发展,基于视频的手语识别与翻译技术研究在国内外受到了越来越多的关注。手语识别与翻译技术的目标是将手语视频转换为文本信息,使得健听人也能够“听懂”手语。手语识别与翻译技术研究能很好的满足聋哑人与健听人之间的沟通需求,打破交流障碍,并提供一个更加客观准确的手语识别与翻译途径,让聋哑得到与普通人的正常生活与学习的机会。如图 1 所示,手语识别与手语翻译是手语研究的两个核心内容。手语识别旨在将手语视频转换为与手语语序相同的手语词序列;而手语翻译的目的则是将手语视频转换为符合口语语序的通顺句子。手语识别与手语翻译之间是一种递进的关系,由于手语视频与口语文本之间的语序与语法规则存在较大的差异,并且二者在语义上的跨度很大,使得直

接将手语视频转换为通顺的语句(Sign2text, S2T)十分困难,并且翻译的准确率不尽如人意。正因如此,研究者们提出了一种手语标注文本(Gloss),其与手语有着相同的语序,将手语视频转换为这种 Gloss 文本类似于单纯的视频识别分类任务,难度更低。在得到了手语标注文本的基础上再进行从 Gloss 序列到通顺的语句的转换就属于单纯的机器翻译问题。通过将手语翻译拆解为两阶段的任务(Sign2Gloss2text, S2G2T),使得最终的翻译准确率得到显著的提高。对于手语识别,其又包含了两种不同的任务,孤立词识别^[2-4]与连续句识别^[5-7]。孤立词手语识别旨在通过输入的包含单个手语词的 video 识别出该 video 对应的手语词。由于整个 video 中仅包含一个手语词,这种识别技术关注的重点在于如何更有效地描述手语的底层特征,并提升识别的准确率。孤立词手语识别针对的是以 video 形式表达的单个孤立手语词汇,相对连续语句而言,其 video 时长较短,语义简单明确。连续句手语识别则是将包含多个手语词的手语 video 序列转换为对应的手语词标注序列,其最大的挑战在于处理手语的连续性,要求算法能够从连续的手语 video 中明确每个手语词之间的边界并正确地将其识别。

2 手语识别与手语翻译研究工作总结

手语识别和手语翻译作为手语研究的核心内容,以下分别从这两个方面对现有相关研究工作进行总结。针对手语识别研究将分别从孤立词手语识别和连续手语识别两方面来展开;手语翻译研究则将分别介绍从手语 video 直接到文本的一阶段方法和从手

语视频到手语标注再进而到文本的两阶段方法, 手语相关研究内容如图2所示。




图1 手语识别-手语翻译与连续手语识别-孤立词手语识别

Fig. 1 Diagram illustrating the differences between sign language recognition and sign language translation, as well as continuous sign language recognition and isolated sign language recognition




图2 手语研究主要内容

Fig. 2 The main context of sign language research

2.1 手语识别研究

早在20世纪90年代就已经开始进行手语识别方面的研究。早期根据手语信息的获取方式不同, 可以分为基于可穿戴设备和基于视觉的手语识别, 前者通过数据手套等可穿戴设备采集到手部实时的三维运动信息并按照时序保存, 然后对得到的时序序列使用识别算法进行处理, 得益于数据手套采集

手部数据的实时性与准确性, 无论是识别准确率还是识别速度都十分可观。但相关设备高昂的价格, 以及穿戴不便等缺陷, 使其难以在真实交流场景中大规模应用。相比之下, 基于视觉的手语识别方法通过处理视频序列就可以完成识别任务, 所以其仅需要使用常见的摄像设备就可以完成数据采集, 这也就使得基于视觉的手语识别方法成为研究的主流。

从手语识别技术的发展上来看,其先后经历了传统识别方法(非深度学习方法)和基于深度学习的方法两个阶段。二者以 2016 年作为分水岭,此前基于视觉的传统手语识别技术研究较为广泛,传统方法往往使用手工的方式进行特征提取,提取到的特征泛化性较差,只能解决特定场景下的手语识别问题,并且所使用的算法往往十分复杂,无法达到大规模应用的程度。随着大数据与深度学习算法的发展,基于深度学习的手语识别技术逐渐成为主流。根据具体研究任务与所使用的主干网络类型的不同,本文将分别对各种方法进行介绍。

2.1.1 孤立词手语识别

视频孤立词识别是手语识别研究中的基础问题之一。其识别的对象是包含单个手语词的视频,相比于连续手语视频,孤立词手语视频时长更短,语义简单明确,所以相关研究最为关注的问题是如何获取能够更加有效地描述手语动作以及更为鲁棒的,研究者们往往都会在特征提取阶段进行相关研究工作以达到优化手语特征表征的目的。针对手语视频的特征提取方法,本文将从非深度学习方法与深度学习方法两个方面进行介绍。图 3 为孤立词手语识别的基本框架。




图 3 孤立词手语识别框架

Fig. 3 Framework of ISLR

2.1.1.1 基于手工特征的孤立词手语识别

视觉特征的提取是手语识别研究的关键。受限于早期计算资源与计算速度的不足,提取视觉特征主要以非深度学习的手工特征为主。由于手语是一种主要使用手部动作以及面部表情表达信息的语言,常用的方法是将手的肤色、形状和运动轨迹等作为视觉特征。Hu 等^[8]使用自适应肤色模型对手部特征进行建模,并使用支持向量机进行分类。但基于肤色与手部形状的视觉特征,难以应对复杂连贯手语视频下的手语识别任务。张永强等^[9]使用三帧间差分法来提取视频中手部的运动轨迹,但是帧间差分

法往往只能提取到运动部分的边界,且依赖于选择的帧间时间间隔,容易受到运动背景的干扰。

为了能够在连贯的孤立词手语视频中提取到更加鲁棒的特征,研究者尝试将诸如尺度不变特征变换(Scale-Invariant Feature Transform, SIFT)^[10]、时空关键点(Spatial Temporal Interesting Points, STIPs)^[11]、梯度直方图(histogram of oriented gradient, HOG)^[12]、内核描述符(Kernel Descriptor)^[13]等二维特征描述子应用于视觉特征提取。在此基础上,Zheng 等^[14]提出了一种方向梯度直方图金字塔的识别方案,并利用三维运动图来构建方向梯度直方图,通过该手段实现对于不同尺度下的手势外观信息的表征。Kovač和 Marák^[2]将自适应 Gabor 滤波器(Gabor Filter)与 SURF(Speed-Up Robust Features, SURF)联合使用,从而增强图像中关键信息。Oliveira 等^[3]提出了一种基于多阶段主成分分析技术(Principal Component Analysis, PCA)的孤立词识别算法,其通过堆叠多层 PCA 完成不断压缩特征维度的目的,提高了识别效率。由于手语的轨迹对手语识别起着重要作用,Lin 等^[15]提出了一种基于流形分析的手语识别方法,并利用 Kinect 捕捉到的三维轨迹识别孤立的手语单词,该方法将三维空间中的轨迹信息视为连续线段的组合,通过分析线段的几何特征来区分不同的曲线模式,进而达到识别手语词的目的。为了得到更为鲁棒的孤立手语词特征,Yin 等^[16]提出了一种鲁棒性模型,其包含一组手语引用和相应的距离度量。手语引用由每个手语词中不受演示者个人习惯影响的特征构成。

基于统计学的方法在特征提取上展现出不俗的潜力。Hussan 等^[17]对手部位置和运行进行均值、标准差、协方差等统计学处理,利用手部相关数据的统计结果作为描述特征。Wang 等^[18]提出了一种基于分层格拉斯曼协方差矩阵(Hierarchical Grassmann Covariance Matrix, HGCM)和多尺度时域置信度传播(Multi-temporal Belief Propagation, MTBP)的模型,其将手语视为多个协方差矩阵的组合,并对其中最为重要的奇异向量进行评估和筛选进而转换成更紧凑、更有辨别力的特征。

在最终的识别分类部分,基于非深度学习的框架通常采用支持向量机^[19]、条件随机场^[20]、随机森林^[21]、视觉词袋^[22]等方法。由于支持向量机的最终分类函数仅由少量的支持向量决定,计算复杂度取决于支持向量数目而非输入样本的维数,剔除了大量的冗余信息,形成了其简单且鲁棒的特点。

Kumar^[23]利用离散小波变换完成对于特征的手工提取, 再将提取到的特征送入支持向量机进行分类。Shah 等^[24]使用多核支持向量机来对手语词进行分类。Yin 等^[25]为了降低特征维度以减少分类时的计算复杂度, 提出了一种基于级联稀疏编码的支持向量机分类器来简化识别过程。

2.1.1.2 基于深度学习的孤立词手语识别

基于手工提取的特征提取方法往往不能很好的兼顾手语中复杂的动态和其他身体关键部位(如: 眉毛、嘴唇和眼睛等)的变化。深度学习方法往往在对空间与时序建模方面拥有者更为强大的能力, 能够对手语演示过程中人工难以察觉的外观与运动细节进行建模。由于不再依赖于手工提取特征, 深度学习方法往往能够提供端到端的训练。

得益于早期在手工特征提取领域所取得的成功, 不少研究者采用手工特征与深度学习方法相结合的方式来进行特征提取。Sincan 和 Keles^[26]提出了一种基于三维卷积神经网络(3D Convolutional Neural Network, 3D CNN)和历史运动图(Motion History Image, MHI)的孤立词手语识别方法。其中, MHI 来源于 RGB 视频, 用于突出显示 3D CNN 所提取到的和运动相关的特征。对于孤立手语词来说, 由于不存在上下文语境, 且单个手语词的类别信息较为明确, 不太需要通过面部变化进行辅助学习, 因而孤立手语词的绝大部分信息都是通过手部来传达的。Lim 等^[27]提出了一种基于手部追踪的孤立词手语识别。该方法主要包含两个主要步骤: 惯用手追踪以及手部特征表征。在手部追踪阶段, 使用带注释的手部数据集提取手部区域, 以对卷积神经网络手部模型进行预训练。粒子滤波器将手部运动和预先训练的 CNN 手部模型结合到联合似然观测模型中, 从而进行手部跟踪。预测的手部位置与联合似然最高的位置相对应。根据预测的手部位置, 以预测位置为中心的长方形手部区域将被分割, 并作为手部表征阶段的输入。在手部特征表征阶段, 通过平均分割的手部区域计算出紧凑的手部表征。获得的手部表征被称为手部能量图像(Hand Energy Image, HEI)。最后使用获得的手部能量图像序列作为输入的手语视频并进行特征提取以及分类。

由于手语主要通过手部形态与手语的运动轨迹来完成信息的传达, 仅仅依赖每一帧的静态画面或者是运动信息都无法实现对于手语词地准确区分与识别, 所以不少研究者尝试将静态手形特征与动态运动轨迹相结合。Pu 等^[28]分别对静态手部形态和

手部运动轨迹进行建模, 提出了一种基于多模态特征的孤立手语词识别方法。该方法主要由两个支路构成, 分别用于提取手部形状以及手部运动轨迹。对于手形部分, 使用三维卷积神经网络来提取手语视频中的手形特征; 对于手部运动轨迹, 则使用三维形状上下文(3D Shape Context)对每一帧的手部关键点进行描述, 最后将两种特征进行概率融合再使用支持向量机进行分类。类似的, Fakhfakh 和 Ben Jemaa^[29]提出了一种两阶段孤立手语词识别方法, 其首先通过预处理将每一帧中关键的面部、手部区域截取出来, 在第一阶段进行静态处理, 进行手部、面部的关键点提取; 第二阶段进行动态处理, 利用提取到的每一帧的关键点信息构建关键点运动轨迹矩阵, 最后将其送入 SVM 分类器进行分类识别。

受益于深度学习的快速发展, 基于各种深度神经网络的特征提取器被广泛地应用于手语识别。卷积神经网络常被用于处理 RGB 视频, 而循环神经网络(Recurrent Neural Network, RNN)、Transformer 等序列模型往往被用于处理骨架等向量序列信息。由于单一尺度、单一模态的信息往往存在一些缺陷, 并不能全面地描述手语词的各方面特征, 所以基于多尺度、多模态的特征提取方法应运而生。Vázquez-Enríquez 等^[30]提出了一种基于多尺度时空卷积的孤立词手语识别算法, 其能够在灵活的时间尺度上利用图中非邻节点之间的语义连通性以提取到更为鲁棒地的特征。此外, Bilge 等^[31]通过计算编码后的描述性文本特征与提取到视觉特征的相似度, 综合视觉与文本特征实现了零样本的连续手语识别。Sincan 等^[32]使用两路平行的卷积神经网络来分别提取 RGB 特征与深度特征, 并将提取到的两路特征通过拼接进行融合。Boháček 和 Hruš 等^[33]采用 Transformer 来处理手部骨架信息, 并应用一系列增强手段来进一步提升识别准确率。

2.1.2 连续手语识别

与孤立词手语识别相比, 连续手语识别需要应对视频中更多的手语词、更复杂的手语动作、更长的视频序列等, 也就意味着需要建立更为可靠的长期时序依赖, 这些都使得连续手语识别更加具有挑战性。因此, 对于每个手语词进行定位以及收集相邻手语词之间边界信息的过程必不可少。但是由于手语词处在连续语境中, 并非互不关联的手语词的拼接, 为了保证手语动作的流畅, 连续句中的手语词的演示动作会受到前后相邻手语词动作的影响而与其标准动作发生变化(标准动作指手语词作为孤立

词使用时的动作), 这种现象一般称为手语动作粘连(Coarticulation)。与语音领域的吞音、连读有所不同, 由于单个手语词的持续时间相较于单个音素更长, 并且手语动作可以在手型、手部位置和运动轨迹等多个维度发生变化, 手语中的粘连现象往往会造成更加严重且长期的影响。

由于早期的研究主要针对孤立词手语识别, 对于孤立词的识别有着成熟的方案方法, 所以部分研究利用视频分割算法, 将连续手语视频分割为多个不同的孤立手语词视频片段, 再采用孤立手语算法进行识别, 最后将各片段识别结果的拼接作为连续

手语识别的最终结果。但是由于相邻手语词粘连现象的存在, 时序分割过程复杂、误判率高, 无论是进行手语词分割还是对分割出的手语词视频片段进行识别都面临着极大的挑战, 使得最终的识别结果不尽如人意。连续手语识别是一种典型的跨学科任务, 需要将输入的视频序列转化为最终的文本序列输出, 目前主流连续手语识别框架采用如图 4 所示的特征提取器加序列对齐模型, 并采用连接时序分类函数(Connectionist Temporal Classification, CTC)^[34] 为损失函数以提供端到端的训练。




图 4 连续手语识别网络架构

Fig. 4 An example of continuous sign language recognition framework

2.1.2.1 基于视频分割的连续手语识别

早期的研究主要针对孤立手语词识别, 所以在面对连续手语词识别问题时, 部分研究者们希望通过视频分割技术将连续手语视频分割为多个孤立手语词片段再通过成熟的孤立手语词识别方法来完成识别任务。由于在识别部分可以沿用已有的孤立手语词识别方法, 该思路的主要难点在于对连续手语视频的准确分割。Han 等^[35] 使用计算机视觉技术与手语语言学来完成分割工作, 他们根据一个手语词是由一系列相互相关联的连续帧组成, 以及手部动作之间的不连续特性开发出了一种简单而有效的方法来检测子单元边界。其最后还通过动态时间规整进行时域聚类, 合并相似的判断来完善结果。Fang 等^[36] 提出了一种基于视觉特征分割与强化学习的连续手语识别方法, 其发现从手语视频中不同手语词中提取的视觉特征存在明显的差异, 并采用强化学

习技术, 将视频中的视觉特征分成多组, 以帮助模型训练。

2.1.2.2 基于传统序列模型的连续手语识别

在连续手语识别任务中, 早期主要采用 CNN+HMM 或者 CNN+HCRF(Hidden Conditional Random Fields)的框架。在连接时序分类损失函数被应用于手语识别之前, 隐马尔可夫模型是使用最为广泛的序列建模方式。HMM 早期主要被应用于语音识别领域, 可以通过隐马尔可夫链来推算状态序列的变化^[37]。在连续手语识别任务中, 状态序列为手语词序列, 观测序列为手语视频序列。连续手语识别问题可以被视为一个典型的 HMM 预测问题, 在给定模型与观测序列的前提下预测可能出现的状态序列(也就是对应的手语标注序列)。Roy 等^[38] 采用肤色检测与连续自适应的 MeanShift 轨迹检测算法进行特征提取后, 应用隐马尔可夫模型对连续手势进行

识别分类。Guo 等^[39]提出了一种自适应的 HMM 手语识别框架, 该框架是基于 HMM 中潜在规律构建的, 该框架根据潜在状态与隐状态之间的转化存在联系, 利用临近传播聚类算法(Affinity Propagation, AP)来对手语的隐状态进行分析与研究。Tornay 等^[40]提出了一种基于 KL 散度指导的隐马尔可夫模型来作为手语识别框架, 他们将提取到的手语特征与观测值计算 KL 散度损失, 并用该损失值来指导 HMM 模型的参数设置。此外, HCRF 也被应用于连续手语识别序列建模中, Yang 和 Lee^[41]利用条件随机场对手语轨迹形状进行建模, 在自建的数据集上性能优于隐马尔可夫模型。

2.1.2.3 基于卷积神经网络的连续手语识别

卷积神经网络(Convolutional Neural Network, CNN)是一种深度学习模型, 被广泛应用于图像分类与图像识别问题中。Wei 等^[42]针对手语的复杂性, 设计了一种兼顾多尺度特征的识别方法, 通过循环神经网络来完成多尺度感知, 以更为全面地学习手语视频的高维特征。除了利用多尺度感知框架, Li 等^[43]通过增加网络的深度以及使用残差连接防止梯度消失, 设计了一个深度达 152 层的残差网络来完成提取手语视频中高维视觉特征的任务。为了缓解连续手语识别的弱监督特性在识别分类过程中带来的不便, Koller 等^[44]提出了一种在弱标记序列数据上训练基于帧的分类器的方法, 由于卷积神经网络对于图像信息中细节特征的强大捕获能力, 他们将其嵌入到最大期望算法当中, 并通过迭代的方式进行强化, 以达到细化帧级标签并提升模型的识别精度的目的。在处理视频输入方面, 三维卷积有着天然的优势, 三维卷积核的使用不仅能够在空间维度进行特征提取, 还能捕获视频帧之间的关联关系。所以大量基于三维卷积神经网络的改进与变种被应用于连续手语识别。Zhou 等^[45]提出了一种基于时空多线索的连续手语识别方案, 在空间维度通过关键区域定位再分别进行卷积形成多路特征, 在时域维度进行单线索内时序特征提取与多线索间时序特征提取。Zou 和 Mak^[46]发现以往的三维卷积神经网络所提取到的特征不能提供准确的手语词之间的边界信息, 提出了一种基于时空分离卷积的变种三维卷积神经网络来保留视频序列中的边界信息。Zhao 等^[47]从多模态数据融合的角度提出了一种双流三维卷积方法来提升识别精度, 该网络包括光流支路与 RGB 支路。Huang 等^[48]将多源视频流在通道维度拼接后输入到三维卷积神经网络, 以达到兼顾颜色、

深度和轨迹信息的目的。

大多数针对基于卷积神经网络的特征提取器的改进工作, 往往都会显著的增加特征提取器的参数量。由于当前主流连续手语数据集的规模都普遍较小, 一般情况下难以支撑参数量较大的特征提取器的训练, 并且在基于特征提取器加序列对齐模型的架构的模型训练中常常会出现序列对齐模型已经拟合而特征提取器仍未收敛的情况, 所以盲目的使用包含更多参数的模型在连续手语识别任务中难以取得理想的效果。Hu 等^[7]提出了一种关联网, 通过计算相邻帧之间的关联度来表征手部的运动轨迹。这种关联度计算是基于像素级的点乘, 不依赖额外的网络结构来完成计算, 并不会增加特征提取器的参数量。由于关联度计算是将整张特征图纳入计算的范畴内, 因此得到的也不只是手部的运动轨迹。所以为了在这些轨迹信息中筛选出连续手势识别任务所需的手部运动轨迹, 其还设计了一种识别模块来帮助完成重要轨迹信息的筛选。

在手语识别方面, 现有的大多数方法都是直接将 RGB 视频编码为特征序列。RGB 视频属于未经处理的原始信号, 存在大量的冗余信息, 这可能导致编码器忽略掉理解手语的关键信息。为了缓解这一问题, 并更好的结合多区域信息(如手形和肢体动作), 因此 Chen 等^[49]提出了一种双模态视觉编码器。其中包含两个独立的视频流, 分别对未经处理的原始视频和由现成手部关键点估计模型生成的关键点序列进行建模。为了使双流信息进行更好的交互, 其采用热力图的方式来表示手部关键点信息, 并使用两个相同的 S3D(Separable 3D Convolutions)模型作为二支路的视觉编码器, 并探索了多种技术进行辅助, 包括双向横向连接、带辅助监督的手势金字塔网络和帧级别的自蒸馏。

2.1.2.4 基于循环神经网络的连续手语识别

手语视频本质上是一种序列信息, 而循环神经网络(Recurrent Neural Network, RNN)是一种专门用于处理序列数据的神经网络, 所以 RNN 以及其后续的改进网络长短期记忆循环神经网络(Long Short Term Memory, LSTM)^[50]和双向长短期记忆循环神经网络(Bi-directional Long Short Term Memory, BiLSTM)^[51]等被应用于手语研究领域。当前主流方法中将各种循环神经网络作为序列对齐模型, 使用连接时序分类把序列对齐问题转化为最大化后验概率的问题, 通过引入空白类并使用动态规划的方式来计算损失, 以提供端到端的训练。Xiao 等^[52]将注意力机制引入

序列建模阶段,设计了一种基于注意力机制的连续手语识别方法。Guo 等^[53]设计了一种基于层次 LSTM 的连续手语识别方案,其中顶层的 LSTM 用于提取视频序列中的时域特征,并引入时域注意力机制来赋予不同位置的视频帧不同的权重;底层使用两个 LSTM 来分别对输入的视觉信息进行编码以及在词嵌入的辅助下进行解码。Mittal 等^[54]提出了一种基于改进的 LSTM 网络的连续手语识别方法,将连续手语视频分割为多个视频片段,在分别对每个片段进行特征提取,随后使用基于 LSTM 的序列建模器对所有视频片段进行建模。

基于 LSTM 的模型有着强大的时序建模能力,但其也存在一些问题。循环神经网络当前状态的计算依赖于前序时间序列的计算结果,导致使用循环神经网络进行的操作不能并行计算,收敛和推理的速度都会因此受到制约。Van Den Oord 等^[55]为了加快训练速度,提出了更加高效、能够实现并行计算的 WaveNet 结构。WaveNet 主要由空洞卷积与因果卷积搭建,使得网络在时域上的感受野能够随着网络层数的增加呈指数型增加,以达到在网络层数一定的前提下急速扩大感受野的目的,得益于网络的超大感受野使其获得了较好的长时依赖建模能力,在处理时序序列问题方面效果卓越。Gehring 等^[56]另辟蹊径,直接舍弃 LSTM,使用全卷积的结构来对序列信息进行建模,由于不再依赖 LSTM 网络,在整个训练与测试阶段,可以实现并行化计算,极大地提升了处理速度。

相较于 LSTM, BiLSTM 能够同时考虑上文与下文的相关信息,展现出了更为强大的序列学习能力, BiLSTM 在连续手语识别领域也受到了许多研究者的青睐。Li 等^[43]提出了一种基于分层搜索的识别方案,将金字塔型的 BiLSTM 网络应用与分层搜索时域范围内的手语关键动作。Min 等^[6]使用 BiLSTM 作为序列学习模型,并将特征提取器所提取到的特征也进行 CTC 解码,在其与最终的预测结果之间进行知识蒸馏,希望将序列模型学习到的对齐信息和文本语义信息迁移到特征提取器中,以缩小视频与文本之间的语义距离,降低后续序列模型的学习难度。Camgoz 等^[57]提出了一种基于 BiLSTM 的端到端的连续手语识别方案,该方法通过将 LSTM 模型进行拆分,将其分解为若干子网络,然后使用 BiLSTM 网络在时间维度分析各子网络的输出并进行关联关系建模,并将 CTC 算法用于手语识别任务,通过 CTC 来完成连续手语识别的标签对齐,

绕开了时序分割,提升了识别的精度。

虽然 CTC 作为解码器有着众多优势,但也存在着一些缺陷。基于 CTC 的解码器,其核心在最大化输入序列与输出序列对齐后的后验概率,由于并不依赖自回归的训练模式,基于连接时序分类的解码器能够避免解码出于手语视频内容不相关的固定句式,但解码出的结果容易缺乏手语语法信息。而 LSTM 也能够作为解码器来使用,并且基于 LSTM 的解码器容易解码出固定模式,解码出的句式相对固定,这就导致其在识别训练集中出现过的手语语句时有着较好的性能。基于两种解码器的特点, Pu 等^[5]提出了一种双解码器的连续手语识别模型,将两种解码器均嵌入到其网络中,训练时并引入动态时间规整(Dynamic Time Warping, DTW)^[58]算法来对齐二解码器的输出,以达到两种解码器互补的目的。

2.1.2.5 基于 Transformer 的连续手语识别

相比于 RNN, Transformer 以多头自注意力机制为核心,并且能够进行并行计算,计算效率更高。由于 Transformer 在自然语言处理中取得了十分优异的成绩,研究者们也将其运用到了连续手语识别当中作为序列对齐模型使用。Zuo 和 Mak^[46]使用一个包含两个 Transformer 编码层的模块为连续手语序列建模,并对特征提取模块和序列建模模块的输出施加了语义一致性约束,防止其过拟合,以发挥 Transformer 强大的序列学习能力。Transformer 不仅能够作为连续手语识别的序列模块使用,其还能够作为一种高效的多模态融合模块来使用。Zhou 等^[59]提出了一种基于交叉注意力机制的识别方法,通过交叉注意力机制来融合不同序列长度的异源数据,以提供更为鲁棒的手语表征。Zhu 等^[60]提出了一种多尺度时序建模网络,通过多尺度时序模块提取不同时域感受野下的时域信息,再利用 Transformer 来对这些不同尺度的特征进行评估与筛选,最终得到更为准确的时域特征。

由于 Transformer 在序列处理任务中的突出表现,研究者们尝试将其运用到图像处理当中,视觉 Transformer(Vision Transformer, ViT)应运而生。Li 等^[61]采用 ViT 对手语视频同时进行时空特征提取,相比于 CNN, ViT 能够更容易地学习到空间距离较远部分之间的关联关系,能够在浅层捕获全局特征,由于手语不仅仅由手部来传达信息,还需要面部表情的参与, ViT 提取全局特征的能力与之恰好契合。

2.1.2.6 基于图卷积神经网络的连续手语识别

图卷积神经网络(Graph Convolution Neural Network, GCN)是一种专门用于处理图结构数据的深度神经网络, 能够有效地学习相邻节点之间地关联关系。由于骨架信息可以过滤掉复杂背景、光照等干扰提供更为清晰的手部、面部表征, 基于骨架信息的手语识别方法往往能够达到更好的效果。骨架信息通常由关键节点与骨骼两种基本元素构成。骨架可以被简化为由点和边构成的图结构。点对应骨架中的关键节点, 边对应骨架中的骨骼。所以基于图卷积神经网络的特征提取方法很自然地应用到连续手语识别问题之中。Guo 等^[62]提出了一种改进的图卷积神经网络, 通过手部特征的移动和解耦操作, 捕捉两个手部节点之间的互动。Jiao 等^[63]提出了一种多线索的图卷积神经网络以更好地利用每个信号的知识, 并提出了互补正则化, 以防止不同信号间复杂的共同适应。此外, 他们还提出了一种双流框架, 可逐步融合骨架数据中的静态和动态信息。Jiang 等^[64]提出了一种骨架感知多模态连续手语识别框架, 首先使用一种手语图卷积网络来对骨架中嵌入的动态信息建模, 再采用时空可分离卷积

网络来进一步提取骨架特征。Tunga^[65]结合 GCN 与 Transformer 来整合骨架信息的时空特征。其使用 GCN 来完成空间维度的骨架信息编码, 随后使用 Transformer 来构建帧之间的时序依赖关系。目前手语识别中使用 GCN 模型主要用于解决单一骨架模态的数据建模问题。

2.2 手语翻译研究

2.2.1 手语视频到文本的手语翻译

手语翻译的目标是将演示连续手语的视频转化为等效的自然语言语句。最为理想、便捷的方案是直接把手语视频翻译为通顺的口语语句, 不经过其他中间模态的过渡, 即 Sign2Text, 典型的基于编码器-解码器结构的 S2T 手语翻译框架如图 5 所示。Camgoz 等^[66]提出了一种基于注意力循环神经网络的编码器-解码器结构来完成 Sign2Text 的翻译任务, 其研究了从手语视频或者手语标注来进行翻译。Zhang 等^[67]采用一种基于异质注意力的 Transformer 编码器-解码器结构, 在编码器中使用双流稀疏注意力(Dual-stream Sparse Attention, DSS)对视频序列进行时序特征学习。




图 5 基于编码器-解码器的 S2T 手语翻译框架

Fig. 5 Encoder-decoder based S2T sign language translation framework

相比于两阶段的 Sign2Gloss2Text 翻译方式, Sign2Text 结构虽然简化了手语翻译模型,但是由于手语视频到通顺口语语句的跨度过大,同时受限于手语翻译数据量的瓶颈和长期依赖等问题,编码器-解码器架构的翻译模型很得到充分地训练。由于手语翻译任务涉及视觉和文本这两种表征差异较大但高层语义信息一致的模态转换,Zhou 等^[68]采用掩码预训练的方式让基于编码器-解码器结构的语言模型学习手语的相关知识,再通过变种的语言-图像对比学习预训练(Contrastive Language-Image Pre-training, CLIP)对视觉编码器与文本编码器进行对比学习,以缩小视频与文本之间的语义跨度,最终将视觉编码器与语言模型的解码器组合为一个完整的 Sign2Text 手语翻译模型。该方法通过将语言-图像对比预训练与掩码监督学习相结合,来弥合视觉和文本表征之间的语义鸿沟。

2.2.2 手语视频到手语标注到文本的手语翻译

由于手语视频与口语语句之间的语义跨度较大,在没有中间模态过渡的情况下很难得到较好的翻译效果。研究者们引入了一种手语标注(Gloss)作为中间过渡,由此,手语翻译过程被分为两个阶段;第一阶段将手语视频转化为手语标注序列;第二阶段将手语标注序列转化为口语文本。第一阶段类似单纯的连续动作识别工作,而第二阶段则更接近于语言翻译任务。通过将手语翻译拆解为两阶段的任务,大量针对连续手语识别的研究都可以被运用到手语翻译任务的第一阶段当中。只需要在连续手语识别网络之后添加一个机器翻译模块就可以完成手语翻译的工作。现存的手语翻译数据库规模都难以支持一个完备翻译模型的训练,Zhou 等^[69]提出了一种反翻译方案,通过训练一个反翻译模型,来将通顺口语语句反翻译为手语词标注序列,并通过建立一个视频片段-标注词库,来完成从标注序列到手语视频的转换。通过这个反翻译流程,来生成原本数据集中不存在的语句-标注对和标注-视频对,以达到扩充数据集的目的。Chen 等^[70]借鉴迁移学习的方式,使用大量通用域的人体动作数据和手语识别领域的连续手语数据来对连续手语识别网络进行预训练,对于手语标注到口语语句的翻译网络也采用了大量通用域的多语言语料库以及专项的手语标注-口语语句语料库来进行预训练。并设计了一个视觉-语言对应模块来连接二模型,以构成一个完整的两阶段手语翻译模型。

<https://www.journalmc.com>

鉴于传统的 RNN 以及新兴 BERT 模型在自然语言翻译中的优异表现。Chen 等^[48]提出了一种双流手语识别框架,并使用一个在多语言语料库上预训练后的 BERT 模型来作为翻译器。Wang 等^[71]提出了一种联合使用 TCN 与 BGRU(Bidirectional Gated Recurrent Unit)来兼顾长短期时域关联关系的手语翻译方法,充分发挥 TCN 在捕获局部时域特征和 BGRU 在建立长期依赖关系上的优势,并设计了一个融合模块来融合 TCN 与 BGRU 的捕获的局部与全局时域关联关系,以达到互补的目的。此外,Song 等^[72]将三维残差网络作为特征提取器,并结合 CNN 与 RNN 的优势设计了一种支持并行处理的序列编码器,其能够并行的处理局部与全局时序关联关系。

3 数据集及评价指标

3.1 手语数据集

大规模的手语数据集是基于深度学习的手语识别与翻译技术发展的基础。由于基于 RGB 视频的视觉特征采集方便,成本低廉,并且还能够较为全面地展示演示者的手部动作、面部表情以及体态等信息,大量基于视觉特征的数据集与研究应运而生。在采用视觉特征的手语识别与翻译研究中,由摄像机拍摄的彩色视频数据在经过一系列图像处理之后被输入到手语识别与翻译模型中。此外,深度以及手部关键点骨架等信息往往作为 RGB 数据的辅助信息。

随着手语研究技术的快速发展,研究者们对于大规模、多语种的手语数据集的需求日益增加。如表 1 所示,根据所对应的口语不同,目前已有包括中国、德国、美国、希腊、波兰、意大利、韩国、阿拉伯等 30 余个国家和地区的手语数据集。根据所针对手语任务的不同,手语数据集又可以被分为两类:孤立词手语数据集和连续手语数据集。

3.1.1 孤立词手语数据集

孤立词手语数据集涵盖的语种较为全面,但是各个数据集的大小规模差异较大,其中数据量较大的数据集包括中文数据集 USTC-CSL5000^[74]和 CSSL5000^[75],英国手语数据集 DISFA^[83]等。这些数据集所包含的手语视频数量都在 100 000 条以上。此外,还有许多数据量很小的数据集,这些数据集的数据量都在 10 000 条以下,例如中文手语数据集 NMFs-CSL^[4],美国手语数据集 Boston ASLLVD^[76],

表 1 主流手语数据集总结
Tab. 1 Summary of the mainstream sign language datasets

数据集	语言	类型	属性		
			手语词数	视频数	演示者数
DEVISIGN-G/D/L ^[73]	中国手语	孤立词	36/500/2000	24 000	8
USTC-CSL500 ^[74]	中国手语	孤立词	500	125 000	50
CSSL5000 ^[75]	中国手语	孤立词	1 000	100 000	10
NMFs-CSL ^[4]	中国手语	孤立词	1 067	1 412	40
Boston ASLLVD ^[76]	美国手语	孤立词	2 742	9 794	6
MS-ASL ^[77]	美国手语	孤立词	1 000	25 513	222
WLASL-LEX ^[78]	美国手语	孤立词	800	10 017	3
WLASL2000 ^[79]	美国手语	孤立词	2000	—	—
AUSLAN ^[80]	澳大利亚手语	孤立词	—	1 100	100
Montalbano V2 ^[81]	意大利手语	孤立词	20	>14 000	—
BSL Corpus ^[82]	英国手语	孤立词	5 000	—	249
DISFA ^[83]	英国手语	孤立词	—	130 000	27
BSL-1K ^[84]	英国手语	孤立词	1 064	1 412	40
PSL Kinect30 ^[85]	波兰手语	孤立词	30	300	1
PSL ToF ^[85]	波兰手语	孤立词	84	1 680	1
LSE-sign ^[86]	西班牙手语	孤立词	2 400	2 400	2
LSA64 ^[87]	阿根廷手语	孤立词	64	3 200	10
SMILE ^[88]	德国手语	孤立词	—	—	30
DSG Kinect40 ^[89]	德国手语	孤立词	40	3 000	15
BosphorusSign22K ^[90]	土耳其手语	孤立词	744	22 542	6
AUTSL ^[91]	土耳其手语	孤立词	226	38 336	43
INCLUDE ^[92]	印度手语	孤立词	263	4 287	7
GSL isoL ^[93]	希腊手语	孤立词	310	10 290	—
KSL ^[94]	韩国手语	孤立词	77	1 229	20
SIGNUM ^[87]	德国手语	孤立词+连续句	455	1 230	25
RWTH-PHOENIX-WEATHER-2014 ^[95]	德国手语	连续句	1 081	6 841	9
RWTH-PHOENIX-WEATHER-2014T ^[66]	德国手语	连续句	1 066	8 257	9
USTC-CCSL ^[58]	中国手语	连续句	178	25 000	50
CSL-Daily ^[96]	中国手语	连续句	2000	20 654	10
RCSD ^[18]	中国手语	连续句	242	—	10
Boston-104 ^[97]	美国手语	连续句	128	214	3
How2Sign ^[98]	美国手语	连续句	16 000	2 500	11
S-pot ^[99]	芬兰手语	连续句	—	5 539	5
KETI ^[100]	韩国手语	连续句	524	14 672	14
GSL ^[93]	希腊手语	孤立词+连续句	310	10 290	7
MEDIAPI-SKEL corpus ^[101]	法国手语	连续句	14 383	368	>100

澳大利亚手语数据集 AUSLAN^[80], 英国手语数据集 BSL-1K^[73], 韩国手语数据集 KSL^[77] 等, 其中 AUSLAN 数据集更是仅包含 1 100 条手语视频。这些小规模的数据集受限于数据量, 只能支持一些小型模型的训练, 或是作为迁移学习中的微调数据来使用。众多孤立词手语数据集不仅在数据集规模上各异, 其所包含的数据种类与来源也各有不同。例如中文词汇数据集 USTC-CSL500^[74] 和 DEVISIGN^[73], 以及英文单词数据集 RWTH-Boston-50^[91] 等都包含多源数据, USTC-CSL500 和 DEVISIGN 包含 RGB, 深度以及骨架这 3 种模态的手语数据, RWTH-Boston-50 则带有多视角的 RGB 和黑白图像, PSL Kinect30^[85] 包含深度与骨架数据, KSL^[94] 则是拥有 RGB 与光流两种模态的数据。这些不同模态的数据可以相互互补以达到优化手语词汇识别的目的。

3.1.2 连续手语数据集

连续手语数据集都是含有多个手语词的完整手语语句视频, 其数据规模相较于孤立词手语数据集普遍较小。当前在包含的词汇量与数据量上最为丰富的数据集 CSL-Daily^[96] 也仅囊括了日常生活中常用的 2 000 种手语词汇, 总共 20 654 条连续手语视频。连续手语数据集虽然都带有 Gloss 标签, 但是其中仅有一部分带有与口语语序相同的文本标签,

只有这一部分数据集能够用于手语翻译任务。能够用于手语翻译任务的数据集主要包括: 中文手语数据集 USTC-CCSL^[58]、CSL-Daily^[96]、美国手语数据集 Boston-104^[97]、德国手语数据集 RWTH-PHOENIX-WEATHER-2014-T^[66]、RWTH-PHOENIX-WEATHER-2014^[95], 韩国手语数据集 KETI^[86]、希腊手语数据集 GSL^[93] 及法国手语数据集 MEDIAPISKELE corpus^[88]。其中, 目前使用较多的主流连续手语数据集主要包括: CSL-Daily 数据集、USTC-CCSL 数据集、RWTH-PHOENIX-WEATHER-2014 数据集及 RWTH-PHOENIX-WEATHER-2014-T 数据集。当前常被用于手语翻译任务的数据集包括: CSL-Daily 和 RWTH-PHOENIX-WEATHER-2014-T。[表 2](#) 展示了当前在这两个数据集上的一些先进方法, 其中 R 代表 ROUGE, B 代表 BLEU。

RWTH-PHOENIX-WEATHER-2014 是一个针对连续手语识别任务的德国手语数据集, 其录制自德国天气预报。数据集中包含 9 名演示者在分辨率为 210×260 的干净背景下播出的天气预报视频。其包含 6 841 个句子视频, 1 295 类手语词, 数据集被划分为 5 672 个训练样本, 540 个验证样本以及 629 个测试样本。如[表 3](#) 所示, 是当前在该数据集上针对连续手语识别任务的一些先进方法, 评价指标为误字率。

表 2 CSL-Daily 和 Phoenix-4T 数据集上先进的手语翻译方法

Tab. 2 State-of-the-art SLT methods on CSL-Daily and Phoenix-2014T. (R: ROUGE, B: BLEU)

		Dev					Test						
		R	B1	B2	B3	B4	R	B1	B2	B3	B4		
Phoenix-2014T	S2G2T	SL-Luong ^[66]	44.14	42.88	30.30	23.02	18.40	43.80	43.29	30.39	22.82	18.13	
		Joint-SLRT ^[102]	—	47.73	34.82	27.11	22.11	—	48.47	35.35	27.57	22.45	
		SignBT ^[69]	49.53	49.33	36.43	28.66	23.51	49.35	48.55	36.13	28.47	23.51	
		STMC ^[45]	46.31	48.27	35.20	27.47	22.47	46.77	48.73	36.53	29.03	24.00	
		MMTLB ^[70]	50.23	50.36	37.50	29.69	24.63	49.59	49.94	37.28	29.67	24.60	
		TSN ^[49]	52.01	52.35	39.76	31.85	26.47	51.59	52.11	39.81	32.00	26.71	
		SL-Luong ^[66]	31.80	31.87	19.11	13.16	9.94	31.80	32.24	19.03	12.83	9.58	
		TSPNet	—	—	—	—	—	34.96	36.10	23.12	16.88	13.41	
		Joint-SLRT ^[102]	—	47.26	34.40	27.05	22.38	—	46.61	33.73	26.19	21.32	
		S2T	STMC ^[45]	48.24	47.60	36.43	29.18	24.09	46.65	46.98	36.09	28.70	23.65
			SignBT ^[69]	50.29	51.11	37.90	29.80	24.45	49.54	50.80	37.75	29.72	24.32
			MMTLB ^[70]	53.10	53.95	41.12	33.14	27.61	52.65	53.97	41.75	33.84	28.39
			TSN ^[49]	54.08	54.32	41.99	34.15	28.66	53.48	54.90	42.43	34.46	28.95

续表 2

			Dev					Test				
			R	B1	B2	B3	B4	R	B1	B2	B3	B4
CSL-Daily	S2G2T	SL-Luong ^[66]	40.18	41.46	25.71	16.57	11.06	40.05	41.55	25.73	16.54	11.03
		Joint-SLRT ^[102]	44.18	46.82	32.22	22.49	15.94	44.81	47.09	32.49	22.61	16.24
		SignBT ^[69]	48.38	50.97	36.16	26.26	19.53	48.21	50.68	36.00	26.20	19.67
		MMTLB ^[70]	51.35	50.89	37.96	28.53	21.88	51.43	50.33	37.44	28.08	21.46
		TSN ^[49]	53.91	53.58	40.49	30.67	23.71	54.92	54.08	41.02	31.18	24.13
	S2T	SL-Luong ^[66]	34.28	34.22	19.72	12.24	7.96	34.54	34.16	19.57	11.84	7.56
		Joint-SLRT ^[102]	37.06	37.47	24.67	16.86	11.88	36.74	37.38	24.36	16.55	11.79
		SignBT ^[69]	49.49	51.46	37.23	27.51	20.80	49.31	51.42	37.26	27.76	21.34
		MMTLB ^[70]	53.38	53.81	40.84	31.29	24.42	53.25	53.31	40.41	30.87	23.92
		TSN ^[49]	55.10	55.21	42.31	32.71	25.76	55.72	55.44	42.59	32.87	25.79

表 3 RWTH-PHOENIX-WEATHER-2014

数据集上的先进方法

Tab. 3 State-of-the-art CSLR methods on RWTH-PHOENIX-WEATHER-2014

Methods	Dev/%	Test/%
SubUNets ^[57]	40.8	40.7
IAN ^[5]	37.1	36.7
SFL ^[103]	24.9	25.3
DNF(RGB) ^[104]	23.8	24.4
FCN ^[75]	23.7	23.9
CMA ^[105]	21.3	21.9
VAC ^[6]	21.2	21.9
STMC ^[45]	21.1	20.7
C ² LSR ^[46]	20.5	20.4
CorrNet ^[7]	18.8	19.4
TSN ^[49]	18.4	18.8

RWTH-PHOENIX-WEATHER-2014-T 同样录制自德国天气预报, 也由 9 名演示者进行手语演示。该数据集可以用于连续手语识别和手语翻译任务。数据集中包含 8 247 个句子视频, 1 085 类手语词, 这些视频被划分为 7 096 个训练样本, 519 个验证样本和 642 个测试样本。表 4 展示了该数据集上的一些先进连续手语识别方法。

CSL-Daily 是针对连续手语识别与翻译的中国手语数据集。数据集的内容围绕日常生活, 由 10

名演示者于室内以 30 frame/s 的帧率录制。其包含 20 654 个句子视频, 2000 类手语词, 被划分为 18 401 个训练样本, 1 077 个验证样本以及 1 176 个测试样本。CSL-Daily 是当前包含连续手语视频最多的公开数据集。表 5 展示了该数据集上的一些先进连续手语识别方法。

表 4 RWTH-PHOENIX-WEATHER-2014-T

数据集上的先进方法

Tab. 4 State-of-the-art CSLR methods on RWTH-PHOENIX-WEATHER-2014-T

Methods	Dev/%	Test/%
SFL ^[103]	25.1	26.1
DNF(RGB) ^[104]	23.3	25.1
FCN ^[75]	23.3	25.1
SignBT ^[69]	22.7	23.9
C ² LSR ^[46]	20.2	20.4
STMC ^[45]	19.6	21.0
CorrNet ^[7]	18.9	20.5
TSN ^[49]	17.7	19.3

USTC-CSL 是由 50 名演示者在实验环境中录制的, 可用于连续手语识别, 手语词词汇量为 178 个, 包含 100 类句子。数据集总共录制了 25 000 个视频, 并以 8 : 2 的比例分为训练集与测试集。表 6 展示了该数据集上的一些先进连续手语识别方法。

表 5 CSL-Daily 数据集上的先进方法
Tab. 5 State-of-the-art CSLR methods on CSL-Daily

Methods	Dev/%	Test/%
SubUNet ^[57]	41.4	41.0
LS-HAN ^[58]	39.0	39.4
SignBT ^[69]	33.2	33.2
FCN ^[75]	33.2	32.5
DNF(RGB) ^[104]	32.8	32.4
CorrNet ^[7]	30.6	30.1
TSN ^[49]	25.4	25.3

表 6 USTC-CSL 数据集上的先进方法
Tab. 6 State-of-the-art CSLR methods on USTC-CSL

Methods	$R_{WE}/\%$
LS-HAN ^[58]	17.3
SubUNet ^[57]	11.0
SF-Net ^[106]	3.8
FCN ^[75]	3.0
STMC ^[45]	2.1
VAC ^[6]	1.6
C^2LSR ^[46]	0.9
CorrNet ^[7]	0.8

3.2 评价指标

3.2.1 手语识别评价指标

对于孤立词手语识别，因为类似单纯的动作识别分类问题，当前通常采用准确率(Accuracy, 记为 A)和召回率(Recall, 记为 R)进行评价。一般情况下准确率或者召回率越高，则表示识别效果越好。准确率又叫查准率，表示在所有的样本中得到正确分类结果的样本所占的比例。在实际应用中，通常采用 Top-1 准确率和 Top-5 准确率来评价。Top-1 准确率将预测结果中概率值最大的类别作为识别结果，若其为正确分类结果则正确，反之则错误；Top-5 准确率取预测中概率最大的 5 类作为识别结果，如果正确结果在这 5 个之中则正确，反之则错误。召回率又叫查全率，表示样本中的正例被预测为正确的比例。

$$A = \frac{TP + TN}{P + N} \quad (1)$$

式中： TP 为被正确分类为正例的数量； TN 为被正确分类为负例的数量； P 为正样本数； N 为负样本数。

<https://www.journalmc.com>

对于连续手语识别，误字率(Word Error Rate, WER, 记为 R_{WE})^[107]和准确率通常被作为评价指标。误字率的作用在于评价预测文本与真实文本之间的错误率，也就是将预测句子转换为参考句子时需要进行的插入、删除以及替换操作的最小次数与参考句子种总词数的比例。

$$R_{WE} = \frac{I + D + S}{N} \quad (2)$$

式中： I 为需要进行的插入操作的次数； D 为删除操作的次数； S 为替换操作的次数； N 为参考句子的总词数。因此，准确率的公式可表示为

$$A = \frac{S + I + D}{N} \quad (3)$$

3.2.2 手语翻译评价指标

由于手语翻译于自然语言翻译任务的最终输出均为通顺的自然语句，所以手语翻译的评价体系于自然语言翻译相似，主要采用 BLEU(Bilingual Evaluation Understudy)^[108]、CIDRR(Consensus-based Image Description Evaluation)^[109]、ROUGE(Recall-oriented Understanding for Gisting Evaluation)^[110]和 METEOR^[111]进行评价。

(1) BLEU

BLEU 即双语互译质量评估辅助工具，顾名思义其时用于评估机器翻译质量的一种工具。BLEU 算法的核心思想是评估两个句子的相似程度，这一相似程度由 BLEU 分数来表现。该分数取值范围为 $[0, 1]$ ，分数值越接近 1 则表示预测句子与参考句子的相似度越好，翻译的质量也就越好。BLEU 引入了一个 n 元组(n -gram)的概念，其表示句子中 n 个连续的单词序列。而 BLEU 值则是预测语句中的 n -gram 也同时出现在参考句子中的数量与预测句子中 n -gram 总数的比值。根据 n -gram 中 n 的取值可以划分成多种评价指标，如 BLEU-1、BLEU-2、BLEU-3、BLEU-4。具体计算公式表示为

$$BLEU_n = \frac{\sum_{c \in \text{candidates}} \sum_{n\text{-gram} \in c} \text{Count}_{\text{clip}}(n\text{-gram})}{\sum_{c' \in \text{candidates}} \sum_{n\text{-gram}' \in c'} \text{Count}(n\text{-gram}')} \quad (4)$$

式中： candidates 为神经网络预测的所有句子； $\sum_{c \in \text{candidates}}$ 统计的是所有的预测句子； $\sum_{n\text{-gram} \in c}$ 统计一条预测句子中的所有 n 元组； $\text{Count}_{\text{clip}}(n\text{-gram})$ 表示某一个 n -gram 在参考句子中出现的次数。所以整个分子是在计算所有的预测句子中有多少个 n -gram 出现在对应参考句子中。类似的，分母则是在计算所有预测句子中的 n -gram 数量。

(2) CIDEr

CIDEr 是基于 BLEU 和向量空间模型的结合, 其主要思想是通过将句子视为一个文档, 然后利用其 n -gram 来计算句子的 TF-IDF 向量, 最后计算预测句子向量与参考句子向量之间的余弦相似度来作为度量标准。CIDEr 通过向量之间的相似度计算其可以兼顾不同长度的 n -gram 之间的匹配, 而且可以通过 TF-IDF 权重赋予不同 n -gram 不同的重要性。但是由于 CIDEr 的计算过程中需要使用 TF-IDF 向量, 而该向量的计算需要大规模的文本数据支撑, 并且其并不能有效地理解句子的语法与结构。具体计算公式为

$$\text{CIDEr}_n(c_i, S_i) = \frac{1}{m} \sum_j \frac{g_n(c_i) \cdot g_n(s_{ij})}{\|g_n(c_i)\| \|g_n(s_{ij})\|} \quad (5)$$

式中: c_i 为预测句子; S_i 为参考句子集合; m 为参考句子数量; n 为 n -gram 长度; $g_n(c_i)$ 、 $g_n(s_{ij})$ 为候选句子和参考句子的 TF-IDF 向量。TF-IDF 向量的计算公式为

$$g_k(s_{ij}) = \sum_{w_l \in \Omega} h_k(s_{ij}) \ln \frac{|I|}{|I_p : w_l \in I_p|} \quad (6)$$

式中: Ω 为所有 n -gram 的集合; $h_k(s_{ij})$ 为 n 元组 w_l 在参考句子 s_{ij} 中出现的次数; $|I|$ 为数据集中所有参考句子的数量; $|I_p : w_l \in I_p|$ 为包含 n 元组 w_l 的参考句子数量。

(3) ROUGE

ROUGE 评价指标经常被使用于机器翻译、问答生成等 NLP 领域。ROUGE 旨在将神经网络生成的预测语句与参考语句进行比较计算, 得到对应的得分。从其评估思路可以看出 ROUGE 指标与 BLEU 指标十分类似, 均是通过在预测句子与参考句子之间进行 n -gram 匹配来进行比较, 不同的是 ROUGE 基于召回率, 而 BLEU 则着重于准确率。主流的方法包括 Rouge-N、Rouge-L、Rouge-W 以及 Rouge-S, 本文主要对 Rouge-N 评价指标做简要介绍。

Rouge-N 是将网络生成的结果和标准结果按 n -gram 拆分后, 计算召回率。具体计算公式为

$$\text{Rouge-N} = \frac{\sum_{S \in \text{reference}} \sum_{n\text{-gram} \in S} \text{Count}_{\text{match}}(n\text{-gram})}{\text{Count}(n\text{-gram})} \quad (7)$$

式中: $\text{Count}(n\text{-gram})$ 代表参考句子中的 n -gram 数量, 这是因为 ROUGE 更关注召回率。

(4) METEOR

METEOR 通常被用于评估文本生成任务, 例如

机器翻译等。它是一种基于单精度的加权调和平均数和单字召回率, 以及对词序的惩罚的度量方法。METEOR 的特点是它不仅考虑了单词的精确匹配, 还考虑了词干、同义词和其他语言变体的匹配。它还使用了一个调和平均数来平衡准确率和召回率, 以及一个罚因子来惩罚不流畅或不连贯的文本。例如在英语中, *ride* 和 *riding* 在 BLEU 方法中算作不同的词, 在 METEOR 中由于词根相同, 两者算作同一个单词。METEOR 的计算方式与 BLEU 几乎完全一致, 只不过在计算匹配的 n 元组数量时, METEOR 会将一些相同词根的词认定为能够匹配。

4 手语研究的挑战与展望

在手语研究中不仅需要考虑单纯技术层面遇到的挑战, 由于手语研究具有很强的现实意义, 相关技术在实际使用过程中可能会面临的问题也需要得到关注, 目前的手语研究面临着如下挑战。

4.1 手语的地域性差异

由于手语本质上是一种听障人士之间约定俗成的语言, 这也就导致了同一手语在不同地区的存在着显著的差异。同为中文手语, 但是不同地区对于同一个手语词的动作可能存在很大的差异, 并且同一地区对于一个手语词也可能存在多个不同的手势动作来表示。这对手语识别造成极大的障碍, 由于当前的手语数据集规模普遍较小, 无法涵盖不同地区的所有手语风格, 这也就导致了模型识别的局限性。要从根本上解决该问题, 只能不断地扩充数据集, 或是针对不同地区分别建立不同的手语数据集并以此训练针对性模型。

4.2 相邻手语词粘连现象

在连续手语中, 手语往往以整句的形式出现, 手语语句中通常没有停顿动作, 手语动作之间存在着自然的过渡衔接。这也就意味着同一个手语词, 当其处于不同的上下文语境时, 其动作会发生一些变化, 特别是对手语的开始与结束阶段影响巨大。这种现象即相邻手语词动作粘连。针对相邻手语词动作粘连现象, 目前并没有引起研究者的广泛关注, 当前的主流方法是使用时空分离卷积来进行特征提取, 虽然与三维卷积相比时空分离的卷积能够更好的保留手语词之间的边界信息, 但是由于相邻手语词粘连现象的影响, 在输入视频中手语词之间的边界信息变得十分模糊, 并且两个手语词之间的过渡阶段可能会被错误的识别为不存在于该句中的手语词。这会对后续的序列学习中造成较大影响, 导致

对齐模型难以学习到视频序列与标注序列之间的对齐关系。当前的方案均无法有效的缓解该现象，后续的工作可以针对其展开进一步研究。

4.3 弱监督语句的识别与翻译

由于连续手语识别本质上是一种弱监督学习任务再加之相邻手语词粘连的影响，这就导致很难从手语视频中分割出每个手语词并将其与对应的标签进行映射。为了解决模糊的边界所带来的问题，研究者们尝试了许多方法，但是在识别准确率上大多数都未能取得显著的提升。再进一步拓展到手语翻译任务，由于手语语法规则的特殊性，其在语言层面上主要依赖手部运动和手势的配合，其语序与口语存在着很大不同。此外，在一些常用地助词、连词等的表达上，由于手语词汇与自然语言相比较为欠缺，手语语句也存在着较为明显地简化。这就使得在翻译阶段手语语句和对应地自然语言文本或者口语语句之间不存在一一对应关系。手语自身语言特性使得整个翻译过程难度大大提高。所以如何根据手势识别与翻译任务的特点，对模型进行针对性的改进是未来研究的方向之一。

4.4 多模态特征融合

使用单一模态数据的方法虽然在算法复杂度上存在优势，但是由于单模态数据自身的局限性，这些方法通常都会存在一些缺陷。深度模态数据虽然能够屏蔽掉背景、光照等条件的影响，但是缺少对于手语识别与翻译十分重要的面部表情等细节；使用最为广泛的 RGB 模态数据在采集的便利性上占优，但是由于其作为一种原始数据容易受到拍摄角度、光照条件等的影响。如何将不同模态的数据有效地融合，保留各模态中特有的特征信息并最终得到更为鲁棒的手语特征表征是亟待解决的问题。手语研究领域常见的多模态融合大多是通过将不同模态的特征在通道维度进行拼接(特征融合)，或者是直接在最后阶段将不同模态数据的分类输出进行融合(概率融合)。如何缩小不同模态数据之间的语义跨度，是将不同模态数据进行有效融合达到互补效果的重点之一。

4.5 手语数据集规模较小

当前，手语数据集的规模都很小，与机器翻译相关数据集动辄上百万的数据量相比，依靠当前的手语数据集难以训练一个性能优越的翻译模型。此外手语数据集规模过小还会导致模型训练时出现序列建模模型已经收敛，而特征提取器的参数还未得到充分的问题，这也客观层面阻碍了大规模手语识

<https://www.journalmc.com>

别模型的出现。如今，随着社会需求的改变，手语研究正在从小型的特定场景任务过渡到实际应用中包含大规模词汇的语句理解任务。为了相关手语技术能够在实际生活场景中顺利落地，对于针对大规模手语词汇的手语识别与翻译方法的探索势在必行。

4.6 大型语言模型的应用

现有的手语翻译方法，尤其是基于 S2G2T 思路的研究，在将 Gloss 序列转换为符合口语语序的通顺语句时，往往将其看作一个双语翻译问题。通常采用在多语种数据集上预训练过的 BERT 或者 mBART 等模型来完成手语翻译工作。随着近年来大规模语言模型的兴起，大模型强大的学习能力使之极有可能成为完成手语翻译的一种潜在工具。大模型拥有数以千亿计的参数量，为其理解标准不统一的复杂自然手语提供了强有力的支持。手语不仅仅是手势的组合，还包括面部表情和身体语言，这些非手势元素对句子的语法结构有重要影响。大规模语言模型可以学习这些复杂的语法规则，并生成语法正确的句子。大模型理解不同语种语料的能力也就是其小样本学习以及微调的能力可以在一定程度上缓解手语数据匮乏的问题。除此之外，一些大模型还能够整合跨模态信息，这与手语研究的跨模态特性恰好契合，可以通过跨模态学习更好的理解手语语义，提高手语翻译的准确性和流畅性。因此大规模语言模型在手语中的应用是今后研究的重点之一。

5 结束语

手语识别与翻译是一个典型的跨学科交叉研究，并且其对于现实世界有着十分重要的社会意义。文章对近年来的手语识别与手语翻译相关研究根据其任务类型和所使用的主要方法进行归纳整理，介绍手语相关研究的发展历程以及当前主流方法的情况与特点。此外还介绍了手语识别与翻译研究所涉及的数据集和评价指标，并列举了当前在手语识别与翻译任务中的先进方法。希望未来的研究能够在大规模数据集匮乏、相邻手语词粘连、视频序列与标注序列对应关系缺失以及多模态数据融合困难等方面取得突破，并在真实应用场景中解决相关问题。

参考文献:

- [1] 世界卫生组织. 世界听力报告[EB/OL]. <https://cdn.>

- who.int/media/docs/default-source/documents/health-topics/deafness-and-hearing-loss/world-report-on-hearing/wrh-exec-summary-ch.pdf, 2021.
- World Health Organization. World report on hearing[EB/OL]. <https://cdn.who.int/media/docs/default-source/documents/health-topics/deafness-and-hearing-loss/world-report-on-hearing/wrh-exec-summary-ch.pdf>, 2021.
- [2] KOVAČ I, MARÁK P. Finger vein recognition: Utilization of adaptive Gabor filters in the enhancement stage combined with sift/surf-based feature extraction[J]. *Signal, Image and Video Processing*, 2023, 17(3): 635-641. DOI: [10.1007/s11760-022-02270-8](https://doi.org/10.1007/s11760-022-02270-8).
 - [3] OLIVEIRA M, SUTHERLAND A, FAROUK M. Two-stage PCA with interpolated data for hand shape recognition in sign language[C]// 2016 IEEE Applied Imagery Pattern Recognition Workshop (AIPR). Piscataway: IEEE, 2016: 1-4. DOI: [10.1109/AIPR.2016.8010587](https://doi.org/10.1109/AIPR.2016.8010587).
 - [4] LIU T, ZHOU W G, LI H Q. Sign language recognition with long short-term memory[C]// 2016 IEEE international conference on image processing (ICIP). Piscataway: IEEE, 2016: 2871-2875. DOI: [10.1109/ICIP.2016.7532884](https://doi.org/10.1109/ICIP.2016.7532884).
 - [5] PU J F, ZHOU W G, LI H Q. Iterative alignment network for continuous sign language recognition[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 4160-4169. DOI: [10.1109/cvpr.2019.00429](https://doi.org/10.1109/cvpr.2019.00429).
 - [6] MIN Y C, HAO A M, CHAI X J, et al. Visual alignment constraint for continuous sign language recognition[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 11522-11531. DOI: [10.1109/iccv48922.2021.01134](https://doi.org/10.1109/iccv48922.2021.01134).
 - [7] HU L Y, GAO L Q, LIU Z K, et al. Continuous sign language recognition with correlation network[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 2529-2539. DOI: [10.1109/cvpr52729.2023.00249](https://doi.org/10.1109/cvpr52729.2023.00249).
 - [8] HU H Z, ZHOU W G, LI H Q. Hand-model-aware sign language recognition[C]// Proceedings of the 35th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2021: 1558-1566. DOI: [10.1609/aaai.v35i2.16247](https://doi.org/10.1609/aaai.v35i2.16247).
 - [9] 张永强, 宋美霖, 刘天虎, 等. 混合骨骼特征的三帧间差分手势识别方法研究[J]. *智能科学与技术学报*, 2022, 4(4): 592-599. DOI: [10.11959/j.issn.2096-6652.202211](https://doi.org/10.11959/j.issn.2096-6652.202211).
ZHANG Y Q, SONG M L, LIU T H, et al. Research on three frame difference gesture recognition method based on mixed bone features[J]. *Chinese Journal of Intelligent Science and Technology*, 2022, 4(4): 592-599. DOI: [10.11959/j.issn.2096-6652.202211](https://doi.org/10.11959/j.issn.2096-6652.202211).
 - [10] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. *International Journal of Computer Vision*, 2004, 60(2): 91-110. DOI: [10.1023/B:VISI.0000029664.99615.94](https://doi.org/10.1023/B:VISI.0000029664.99615.94).
 - [11] LAPTEV I, MARSZALEK M, SCHMID C, et al. Learning realistic human actions from movies[C]// 2008 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2008: 1-8. DOI: [10.1109/CVPR.2008.4587756](https://doi.org/10.1109/CVPR.2008.4587756).
 - [12] DALAL N, TRIGGS B. Histograms of oriented gradients for human detection[C]// 2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Piscataway: IEEE, 2005: 886-893. DOI: [10.1109/CVPR.2005.177](https://doi.org/10.1109/CVPR.2005.177).
 - [13] BO L F, LAI K, REN X F, et al. Object recognition with hierarchical kernel descriptors[C]// Proceedings of the 24th IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2011: 1729-1736. DOI: [10.1109/CVPR.2011.5995719](https://doi.org/10.1109/CVPR.2011.5995719).
 - [14] ZHENG L H, LIANG B. Sign language recognition using depth images[C]// 2016 14th International Conference on Control, Automation, Robotics and Vision (ICARCV). Piscataway: IEEE, 2016: 1-6. DOI: [10.1109/ICARCV.2016.7838572](https://doi.org/10.1109/ICARCV.2016.7838572).
 - [15] LIN Y S, CHAI X J, ZHOU Y, et al. Curve matching from the view of manifold for sign language recognition[C]// Proceedings of the European Conference on Computer Vision. Heidelberg: Springer, 2015: 233-246. DOI: [10.1007/978-3-319-16634-6_18](https://doi.org/10.1007/978-3-319-16634-6_18).
 - [16] YIN F, CHAI X J, CHEN X L. Iterative reference driven metric learning for signer independent isolated sign language recognition[C]// Proceedings of the 14th European Conference on Computer Vision. Heidelberg: Springer, 2016: 434-450. DOI: [10.1007/978-3-319-46478-7_27](https://doi.org/10.1007/978-3-319-46478-7_27).
 - [17] HASSAN M, ASSALEH K, SHANABLEH T. User-dependent sign language recognition using motion detection[C]// 2016 International Conference on Computational Science and Computational Intelligence (CSCI). Piscataway: IEEE, 2016: 852-856. DOI: [10.1109/CSCI.2016.0165](https://doi.org/10.1109/CSCI.2016.0165).
 - [18] WANG H J, CHAI X J, CHEN X L. A novel sign language recognition framework using hierarchical grassmann covariance matrix[J]. *IEEE Transactions on Multimedia*, 2019, 21(11): 2806-2814. DOI: [10.1109/TMM.2019.2915032](https://doi.org/10.1109/TMM.2019.2915032).
 - [19] AGARWAL A, THAKUR M K. Sign language recognition using Microsoft kinect[C]// 2013 Sixth International Conference on Contemporary Computing (IC3). Piscataway: IEEE, 2013: 181-185. DOI: [10.1109/IC3.2013.6612186](https://doi.org/10.1109/IC3.2013.6612186).

- [20] YANG R D, SARKAR S. Detecting coarticulation in sign language using conditional random fields[C]// 18th International Conference on Pattern Recognition (ICPR'06). Piscataway: IEEE, 2006: 108-112. DOI: [10.1109/ICPR.2006.431](https://doi.org/10.1109/ICPR.2006.431).
- [21] BREIMAN L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5-32. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [22] FEI-FEI L, PERONA P. A Bayesian hierarchical model for learning natural scene categories[C]// 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). Piscataway: IEEE, 2005: 524-531. DOI: [10.1109/CVPR.2005.16](https://doi.org/10.1109/CVPR.2005.16).
- [23] KUMAR N. Sign language recognition for hearing impaired people based on hands symbols classification[C]// 2017 International Conference on Computing, Communication and Automation (ICCCA). Piscataway: IEEE, 2017: 244-249. DOI: [10.1109/CCAA.2017.8229808](https://doi.org/10.1109/CCAA.2017.8229808).
- [24] SHAH F, SHAH M S, AKRAM W, et al. Sign language recognition using multiple kernel learning: a case study of Pakistan sign language[J]. *IEEE Access*, 2021, 9: 67548-67558. DOI: [10.1109/ACCESS.2021.3077386](https://doi.org/10.1109/ACCESS.2021.3077386).
- [25] YIN F, CHAI X J, ZHOU Y, et al. Semantics constrained dictionary learning for signer-independent sign language recognition[C]// 2015 IEEE International Conference on Image Processing (ICIP). Piscataway: IEEE, 2015: 3310-3314. DOI: [10.1109/ICIP.2015.7351416](https://doi.org/10.1109/ICIP.2015.7351416).
- [26] SINCAN O M, KELES H Y. Using motion history images with 3D convolutional networks in isolated sign language recognition[J]. *IEEE Access*, 2022, 10: 18608-18618. DOI: [10.1109/ACCESS.2022.3151362](https://doi.org/10.1109/ACCESS.2022.3151362).
- [27] LIM K M, TAN A W C, Lee C P, et al. Isolated sign language recognition using convolutional neural network hand modelling and hand energy image[J]. *Multimedia Tools and Applications*, 2019, 78(14): 19917-19944. DOI: [10.1007/s11042-019-7263-7](https://doi.org/10.1007/s11042-019-7263-7).
- [28] PU J F, ZHOU W G, LI H Q. Sign language recognition with multi-modal features[C]// 17th Pacific-Rim Conference on Advances in Multimedia Information Processing-PCM 2016. Heidelberg: Springer, 2016: 252-261. DOI: [10.1007/978-3-319-48896-7_25](https://doi.org/10.1007/978-3-319-48896-7_25).
- [29] FAKHFAKH S, BEN JEMAA Y. Gesture recognition system for isolated word sign language based on key-point trajectory matrix[J]. *Computación y Sistemas*, 2018, 22(4): 1415-1430. DOI: [10.13053/cys-22-4-3046](https://doi.org/10.13053/cys-22-4-3046).
- [30] VÁZQUEZ-ENRÍQUEZ M, ALBA-CASTRO J L, DOCÍO-FERNÁNDEZ L, et al. Isolated sign language recognition with multi-scale spatial-temporal graph convolutional networks[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 3457-3466. DOI: [10.1109/cvprw53098.2021.00385](https://doi.org/10.1109/cvprw53098.2021.00385).
- [31] BILGE Y C, CINBIS R G, IKIZLER-CINBIS N. Towards zero-shot sign language recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023, 45(1): 1217-1232. DOI: [10.1109/TPAMI.2022.3143074](https://doi.org/10.1109/TPAMI.2022.3143074).
- [32] SINCAN O M, TUR A O, KELES H Y. Isolated sign language recognition with multi-scale features using LSTM[C]// 2019 27th Signal Processing and Communications Applications Conference (SIU). Piscataway: IEEE, 2019: 1-4. DOI: [10.1109/SIU.2019.8806467](https://doi.org/10.1109/SIU.2019.8806467).
- [33] BOHÁČEK M, HRŮZ M. Sign pose-based transformer for word-level sign language recognition[C]// Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2022: 182-191. DOI: [10.1109/WACVW54805.2022.00024](https://doi.org/10.1109/WACVW54805.2022.00024).
- [34] GRAVES A. Connectionist temporal classification[M]// GRAVES A. Supervised Sequence Labelling with Recurrent Neural Networks. Berlin Heidelberg: Springer, 2012: 61-93. DOI: [10.1007/978-3-642-24797-2_7](https://doi.org/10.1007/978-3-642-24797-2_7).
- [35] HAN J W, AWAD G, SUTHERLAND A. Modelling and segmenting subunits for sign language recognition based on hand motion analysis[J]. *Pattern Recognition Letters*, 2009, 30(6): 623-633. DOI: [10.1016/j.patrec.2008.12.010](https://doi.org/10.1016/j.patrec.2008.12.010).
- [36] FANG Y C, WANG L J, LIN S Q, et al. Visual feature segmentation with reinforcement learning for continuous sign language recognition[J]. *International Journal of Multimedia Information Retrieval*, 2023, 12(2): 39. DOI: [10.1007/s13735-023-00302-8](https://doi.org/10.1007/s13735-023-00302-8).
- [37] 方高林, 高文, 陈熙霖, 等. 基于 SRN/HMM 的非特定人连续手语识别系统[J]. *软件学报*, 2002, 13(11): 2169-2175.
FANG G L, GAO W, CHEN X L, et al. A signer-independent continuous sign language recognition system based on SRN/HMM[J]. *Journal of Software*, 2002, 13(11): 2169-2175.
- [38] ROY P P, KUMAR P, KIM B G. An efficient sign language recognition (SLR) system using Camshift tracker and hidden Markov model (HMM)[J]. *SN Computer Science*, 2021, 2(2): 79. DOI: [10.1007/s42979-021-00485-z](https://doi.org/10.1007/s42979-021-00485-z).
- [39] GUO D, ZHOU W G, LI H Q, et al. Online early-late fusion based on adaptive HMM for sign language recognition[J]. *ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM)*, 2018, 14(1): 8. DOI: [10.1145/3152121](https://doi.org/10.1145/3152121).
- [40] TORNAY S, RAZAVI M, MAGIMAI -DOSS M. Towards multilingual sign language recognition[C]// ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Piscataway: IEEE, 2020: 6309-6313. DOI: [10.1109/ICASSP2020.2020.9053485](https://doi.org/10.1109/ICASSP2020.2020.9053485).

- SP40776.2020.9054631.
- [41] YANG H D, LEE S W. Robust sign language recognition by combining manual and non-manual features based on conditional random field and support vector machine[J]. *Pattern Recognition Letters*, 2013, 34(16): 2051-2056. DOI: [10.1016/j.patrec.2013.06.022](#).
 - [42] WEI C C, ZHAO J, ZHOU W G, et al. Semantic boundary detection with reinforcement learning for continuous sign language recognition[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2021, 31(3): 1138-1149. DOI: [10.1109/TCSVT.2020.2999384](#).
 - [43] LI H B, GAO L Q, HAN R Z, et al. Key action and joint CTC-attention based sign language recognition[C]// ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Piscataway: IEEE, 2020: 2348-2352. DOI: [10.1109/ICASSP40776.2020.9054316](#).
 - [44] KOLLER O, NEY H, BOWDEN R. Deep hand: How to train a CNN on 1 million hand images when your data is continuous and weakly labelled[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 3793-3802. DOI: [10.1109/cvpr.2016.412](#).
 - [45] ZHOU H, ZHOU W G, ZHOU Y, et al. Spatial-temporal multi-cue network for sign language recognition and translation[J]. *IEEE Transactions on Multimedia*, 2022, 24: 768-779. DOI: [10.1109/TMM.2021.3059098](#).
 - [46] ZUO R L, MAK B. C²SLR: consistency-enhanced continuous sign language recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 5121-5130. DOI: [10.1109/cvpr52688.2022.00507](#).
 - [47] ZHAO K, ZHANG K J, ZHAI Y, et al. Real-time sign language recognition based on video stream[J]. *International Journal of Systems, Control and Communications*, 2021, 12(2): 158-174. DOI: [10.1504/IJSCC.2021.114616](#).
 - [48] HUANG J, ZHOU W G, LI H Q, et al. Sign language recognition using 3D convolutional neural networks[C]// 2015 IEEE International Conference on Multimedia and Expo (ICME). Piscataway: IEEE, 2015: 1-6. DOI: [10.1109/ICME.2015.7177428](#).
 - [49] CHEN Y T, ZUO R L, WEI F Y, et al. Two-stream network for sign language recognition and translation [C]// Proceedings of the 36th International Conference on Neural Information Processing Systems. New York: ACM, 2022: 1240.
 - [50] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735-1780. DOI: [10.1162/neco.1997.9.8.1735](#).
 - [51] GRAVES A, FERNÁNDEZ S, SCHMIDHUBER J. Bi-directional LSTM networks for improved phoneme classification and recognition[C]// 15th International Conference on Artificial Neural Networks. Heidelberg: Springer, 2005: 799-804. DOI: [10.1007/11550907_126](#).
 - [52] XIAO Q K, CHANG X, ZHANG X, et al. Multi-information spatial-temporal LSTM fusion continuous sign language neural machine translation[J]. *IEEE Access*, 2020, 8: 216718-216728. DOI: [10.1109/ACCESS.2020.3039539](#).
 - [53] GUO D, ZHOU W G, LI H Q, et al. Hierarchical LSTM for sign language translation[C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2018. DOI: [10.1609/aaai.v32i1.12235](#).
 - [54] MITTAL A, KUMAR P, ROY P P, et al. A modified LSTM model for continuous sign language recognition using leap motion[J]. *IEEE Sensors Journal*, 2019, 19(16): 7056-7063. DOI: [10.1109/JSEN.2019.2909837](#).
 - [55] VAN DEN OORD A, DIELEMAN S, ZEN H, et al. WaveNet: A generative model for raw audio[C]// 9th ISCA Workshop on Speech Synthesis Workshop. [S.I.]: SSW, 2016.
 - [56] GEHRING J, AULI M, GRANGIER D, et al. Convolutional sequence to sequence learning[C]// Proceedings of the 34th International Conference on Machine Learning. [S.I.]: PMLR, 2017: 1243-1252.
 - [57] CAMGOZ N C, HADFIELD S, KOLLER O, et al. SubUNets: End-to-end hand shape and continuous sign language recognition[C]//Proceedings of the IEEE international conference on computer vision. Piscataway: IEEE, 2017: 3075-3084. DOI: [10.1109/iccv.2017.332](#).
 - [58] HUANG J, ZHOU W G, ZHANG Q L, et al. Video-based sign language recognition without temporal segmentation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2018. DOI: [10.1609/aaai.v32i1.11903](#).
 - [59] ZHOU Z X, TAM V W L, LAM E Y. A cross-attention BERT-based framework for continuous sign language recognition[J]. *IEEE Signal Processing Letters*, 2022, 29: 1818-1822. DOI: [10.1109/LSP.2022.3199665](#).
 - [60] ZHU Q D, LI J, YUAN F, et al. Multiscale temporal network for continuous sign language recognition[J]. *Journal of Electronic Imaging*, 2024, 33(2): 023059. DOI: [10.1117/1.JEI.33.2.023059](#).
 - [61] LI R H, MENG L. Multi-view spatial-temporal network for continuous sign language recognition[J]. arXiv: 2204.08747, 2022. DOI: [10.48550/arXiv.2204.08747](#).
 - [62] GUO L, TANG L, CHEN T, et al. DA-GCN: A domain-aware attentive graph convolution network for shared-account cross-domain sequential recommendation[C]// Proceedings of the 30th International Joint Conference on Artificial Intelligence. [S.I.]: IJCAI, 2021.
 - [63] JIAO P Q, MIN Y C, LI Y N, et al. CoSign: Exploring <https://www.journalmc.com>

- co-occurrence signals in skeleton-based continuous sign language recognition[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2023: 20619-20629. DOI: [10.1109/iccv51070.2023.01890](https://doi.org/10.1109/iccv51070.2023.01890).
- [64] JIANG S Y, SUN B, WANG L C, et al. Skeleton aware multi-modal sign language recognition[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 3408-3418. DOI: [10.1109/CVPRW53098.2021.00380](https://doi.org/10.1109/CVPRW53098.2021.00380).
- [65] TUNGA A, NUTHALAPATI S V, WACHS J. Pose-based sign language recognition using GCN and BERT[C]// Proceedings of the IEEE Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2021: 31-40. DOI: [10.1109/wacvw52041.2021.00008](https://doi.org/10.1109/wacvw52041.2021.00008).
- [66] CAMGOZ N C, HADFIELD S, KOLLER O, et al. Neural sign language translation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2018: 7784-7793. DOI: [10.1109/CVPR.2018.00812](https://doi.org/10.1109/CVPR.2018.00812).
- [67] ZHANG H, SUN Y X, LIU Z H, et al. Heterogeneous attention based transformer for sign language translation[J]. *Applied Soft Computing*, 2023, 144: 110526. DOI: [10.1016/j.asoc.2023.110526](https://doi.org/10.1016/j.asoc.2023.110526).
- [68] ZHOU B J, CHEN Z G, CLAPÉS A, et al. Gloss-free sign language translation: Improving from visual-language pretraining[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2023: 20814-20824. DOI: [10.1109/ICCV51070.2023.01908](https://doi.org/10.1109/ICCV51070.2023.01908).
- [69] ZHOU H, ZHOU W G, QI W Z, et al. Improving sign language translation with monolingual data by sign back-translation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 1316-1325. DOI: [10.1109/CVPR46437.2021.00137](https://doi.org/10.1109/CVPR46437.2021.00137).
- [70] CHEN Y T, WEI F Y, SUN X, et al. A simple multi-modality transfer learning baseline for sign language translation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 5110-5120. DOI: [10.1109/CVPR52688.2022.00506](https://doi.org/10.1109/CVPR52688.2022.00506).
- [71] WANG S, GUO D, ZHOU W G, et al. Connectionist temporal fusion for sign language translation[C]// Proceedings of the 26th ACM International Conference on Multimedia. New York: ACM, 2018: 1483-1491. DOI: [10.1145/3240508.3240671](https://doi.org/10.1145/3240508.3240671).
- [72] SONG P P, GUO D, XIN H R, et al. Parallel temporal encoder for sign language translation[C]// 2019 IEEE International Conference on Image Processing (ICIP). Piscataway: IEEE, 2019: 1915-1919. DOI: [10.1109/ICIP.2019.8803123](https://doi.org/10.1109/ICIP.2019.8803123).
- [73] CHAI X J, WANG H J, CHEN X L. The DEVISIGN large vocabulary of Chinese sign language database and baseline evaluations[R]. Beijing: Key Lab of Intelligent Information Processing of Chinese Academy of Sciences (CAS), 2014.
- [74] ZHANG J H, ZHOU W G, XIE C, et al. Chinese sign language recognition with adaptive HMM[C]// 2016 IEEE International Conference on Multimedia and Expo (ICME). Piscataway: IEEE, 2016: 1-6. DOI: [10.1109/ICME.2016.7552950](https://doi.org/10.1109/ICME.2016.7552950).
- [75] CHENG K L, YANG Z Y, CHEN Q F, et al. Fully convolutional networks for continuous sign language recognition[C]// 16th European Conference on Computer Vision. Heidelberg: Springer, 2020: 697-714. DOI: [10.1007/978-3-030-58586-0_41](https://doi.org/10.1007/978-3-030-58586-0_41).
- [76] ATHITSOS V, NEIDLE C, SCLAROFF S, et al. The American sign language lexicon video dataset[C]// 2008 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops. Piscataway: IEEE, 2008: 1-8. DOI: [10.1109/CVPRW.2008.4563181](https://doi.org/10.1109/CVPRW.2008.4563181).
- [77] JOZE H R V, KOLLER O. MS-ASL: A large-scale data set and benchmark for understanding American sign language[C]// 30th British Machine Vision Conference 2019. [S.I.]: BMVC, 2019.
- [78] TAVELLA F, SCHLEGEL V, ROMEO M, et al. WLASL-LEX: A dataset for recognising phonological properties in American sign language[C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. New York: ACL, 2022: 453-463. DOI: [10.18653/v1/2022.acl-short.49](https://doi.org/10.18653/v1/2022.acl-short.49).
- [79] LI D X, OPAZO C R, YU X, et al. Word-level deep sign language recognition from video: A new large-scale dataset and methods comparison[C]// Proceedings of the IEEE Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2020: 1448-1458. DOI: [10.1109/WACV45572.2020.9093512](https://doi.org/10.1109/WACV45572.2020.9093512).
- [80] DUARTE A C. Cross-modal neural sign language translation[C]// Proceedings of the 27th ACM International Conference on Multimedia. New York: ACM, 2019: 1650-1654. DOI: [10.1145/3343031.3352587](https://doi.org/10.1145/3343031.3352587).
- [81] OSZUST M, WYSOCKI M. Polish sign language words recognition with Kinect[C]// 2013 6th International Conference on Human System Interactions (HSI). Piscataway: IEEE, 2013: 219-226. DOI: [10.1109/HSI.2013.6577826](https://doi.org/10.1109/HSI.2013.6577826).
- [82] SCHEMBRI A, FENLON J, RENTELIS R, et al. Building the British sign language corpus[EB/OL]. <https://scholarspace.manoa.hawaii.edu/items/e206e438-734f-4f4b-957a-45a3d6d1593c/full>, 2023
- [83] MAVADATI M, SANGER P, MAHOOR M H. Extended DISFA dataset: Investigating posed and spontaneous facial expressions[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition

- tion Workshops. Piscataway: IEEE, 2016: 1452-1459. DOI: [10.1109/CVPRW.2016.182](https://doi.org/10.1109/CVPRW.2016.182).
- [84] ALBANIE S, VAROL G, MOMENI L, et al. BSL-1K: Scaling up co-articulated sign language recognition using mouthing cues[C]// 16th European Conference on Computer Vision. Heidelberg: Springer, 2020: 35-53. DOI: [10.1007/978-3-030-58621-8_3](https://doi.org/10.1007/978-3-030-58621-8_3).
- [85] ESCALERA S, BARÓ X, GONZÁLEZ J, et al. ChaLearn looking at people challenge 2014: Dataset and results[C]// European Conference Computer Vision. Heidelberg: Springer, 2015: 459-473. DOI: [10.1007/978-3-319-16178-5_32](https://doi.org/10.1007/978-3-319-16178-5_32).
- [86] GUTIERREZ-SIGUT E, COSTELLO B, BAUS C, et al. LSE-sign: A lexical database for Spanish sign language[J]. Behavior Research Methods, 2016, 48(1): 123-137. DOI: [10.3758/s13428-014-0560-1](https://doi.org/10.3758/s13428-014-0560-1).
- [87] RONCHETTI F, QUIROGA F M, ESTREBOU C, et al. LSA64: An Argentinian sign language dataset[J]. arXiv: 2310.17429, 2023. DOI: [10.48550/arXiv.2310.17429](https://doi.org/10.48550/arXiv.2310.17429).
- [88] EBLING S, CAMGÖZ N C, BRAEM P B, et al. SMILE Swiss German sign language dataset[C]// Proceedings of the 11th International Conference on Language Resources and Evaluation (LREC 2018). New York: ACL, 2018.
- [89] COOPER H, ONG E J, PUGEAULT N, et al. Sign language recognition using sub-units[J]. The Journal of Machine Learning Research, 2012, 13(1): 2205-2231.
- [90] ÖZDEMİR O, KINDIROĞLU A A, CAMGÖZ N C, et al. BosphorusSign22k sign language recognition dataset[J]. arXiv: 2004.01283, 2020. DOI: [10.48550/arXiv.2004.01283](https://doi.org/10.48550/arXiv.2004.01283).
- [91] SINCAN O M, KELES H Y. AUTSL: A large scale multi-modal Turkish sign language dataset and baseline methods[J]. IEEE Access, 2020, 8: 181340-181355. DOI: [10.1109/ACCESS.2020.3028072](https://doi.org/10.1109/ACCESS.2020.3028072).
- [92] SRIDHAR A, GANESAN R G, KUMAR P, et al. INCLUDE: A large scale dataset for Indian sign language recognition[C]// Proceedings of the 28th ACM International Conference on Multimedia. New York: ACM, 2020: 1366-1375. DOI: [10.1145/3394171.3413528](https://doi.org/10.1145/3394171.3413528).
- [93] ADALOGLOU N, CHATZIS T, PAPASTRATIS I, et al. A comprehensive study on deep learning-based methods for sign language recognition[J]. IEEE Transactions on Multimedia, 2022, 24: 1750-1762. DOI: [10.1109/TMM.2021.3070438](https://doi.org/10.1109/TMM.2021.3070438).
- [94] YANG S, JUNG S, KANG H, et al. The Korean sign language dataset for action recognition[C]// 26th International Conference on Multimedia Modeling. Heidelberg: Springer, 2020: 532-542. DOI: [10.1007/978-3-030-37731-1_43](https://doi.org/10.1007/978-3-030-37731-1_43).
- [95] FORSTER J, SCHMIDT C, KOLLER O, et al. Extensions of the sign language recognition and translation corpus RWTH-PHOENIX-Weather[C]// Proceedings of the Ninth International Conference on Language Resources and Evaluation. [S.I.]: LREC, 2014: 1911-1916.
- [96] YIN K, READ J. Better sign language translation with STMC-transformer[C]// Proceedings of the 28th International Conference on Computational Linguistics. New York: ACL, 2020: 5975-5989. DOI: [10.18653/v1/2020.coling-main.525](https://doi.org/10.18653/v1/2020.coling-main.525).
- [97] DREUW P, FORSTER J, DESELAERS T, et al. Efficient approximations to model-based joint tracking and recognition of continuous sign language[C]// 2008 8th IEEE International Conference on Automatic Face & Gesture Recognition. Piscataway: IEEE, 2008: 1-6. DOI: [10.1109/AFGR.2008.4813439](https://doi.org/10.1109/AFGR.2008.4813439).
- [98] DUARTE A, PALASKAR S, VENTURA L, et al. How2Sign: A large-scale multimodal dataset for continuous American sign language[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 2734-2743. DOI: [10.1109/CVPR46437.2021.00276](https://doi.org/10.1109/CVPR46437.2021.00276).
- [99] VIITANIEMI V, JANTUNEN T, SAVOLAINEN L, et al. S-pot-a benchmark in spotting signs within continuous signing[C]// Proceedings of the Ninth International Conference on Language Resources and Evaluation. [S.I.]: LREC, 2014.
- [100] KO S K, KIM C J, JUNG H, et al. Neural sign language translation based on human keypoint estimation[J]. Applied Sciences, 2019, 9(13): 2683. DOI: [10.3390/app9132683](https://doi.org/10.3390/app9132683).
- [101] COOKSON C J, OSTROVER L S. Method and system of mass producing double-sided optical discs: US, 7362692B2[P]. 2008-04-22.
- [102] CAMGÖZ N C, KOLLER O, HADFIELD S, et al. Sign language transformers: Joint end-to-end sign language recognition and translation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 10020-10030. DOI: [10.1109/CVPR42600.2020.01004](https://doi.org/10.1109/CVPR42600.2020.01004).
- [103] NIU Z, MAK B. Stochastic fine-grained labeling of multi-state sign glosses for continuous sign language recognition[C]// 16th European Conference on Computer Vision. Heidelberg: Springer, 2020: 172-186. DOI: [10.1007/978-3-030-58517-4_11](https://doi.org/10.1007/978-3-030-58517-4_11).
- [104] CUI R P, LIU H, ZHANG C S. A deep neural framework for continuous sign language recognition by iterative training[J]. IEEE Transactions on Multimedia, 2019, 21(7): 1880-1891. DOI: [10.1109/TMM.2018.2889563](https://doi.org/10.1109/TMM.2018.2889563).
- [105] PU J F, ZHOU W G, HU H Z, et al. Boosting continuous sign language recognition via cross modality augmentation[C]// Proceedings of the 28th ACM International Conference on Multimedia. New York: ACM, <https://www.journalmc.com>

- 2020: 1497-1505. DOI: [10.1145/3394171.3413931](https://doi.org/10.1145/3394171.3413931).
- [106] YANG Z Y, SHI Z M, SHEN X Y, et al. SF-Net: Structured feature network for continuous sign language recognition[J]. arXiv: 1908.01341, 2019. DOI: [10.48550/arXiv.1908.01341](https://doi.org/10.48550/arXiv.1908.01341).
- [107] EIDE E, GISH H, JEANRENAUD P, et al. Understanding and improving speech recognition performance through the use of diagnostic tools[C]// 1995 International Conference on Acoustics, Speech, and Signal Processing. Piscataway: IEEE, 1995: 221-224. DOI: [10.1109/ICASSP.1995.479404](https://doi.org/10.1109/ICASSP.1995.479404).
- [108] PAPINENI K, ROUKOS S, WARD T, et al. BLEU: A method for automatic evaluation of machine translation[C]// Proceedings of the 40th Annual Meeting on Association for Computational Linguistics. New York: ACM, 2002: 311-318. DOI: [10.3115/1073083.1073135](https://doi.org/10.3115/1073083.1073135).
- [109] VEDANTAM R, LAWRENCE ZITNICK C, PARIKH D. CIDEr: Consensus-based image description evaluation[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2015: 4566-4575. DOI: [10.1109/CVPR.2015.7299087](https://doi.org/10.1109/CVPR.2015.7299087).
- [110] LIN C Y. ROUGE: A package for automatic evaluation of summaries[C]// Text summarization branches out. Barcelona, Spain: Association for Computational Linguistics, 2004: 74-81.
- [111] BANERJEE S, LAVIE A. METEOR: An automatic metric for MT evaluation with improved correlation with human judgments[C]// Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization. New York: ACL, 2005: 65-72.

作者简介:

李宇楠 博士, 副教授, yunanli@xidian.edu.cn

苗启广(通信作者) 博士, 教授, qgmiao@xidian.edu.cn